


¿Quién va a contratar un plazo fijo?

Grupo 7 — Andrés Cortese (64612) · Sebastián Caules (64331)
Instituto Tecnológico de Buenos Aires — 72.75 Aprendizaje Automático

Dataset: *Bank Marketing* — 41 188 contactos de campañas telefónicas de un banco, de 2008 a 2010
Defensa: 14/10/2026


El problema y el desbalance de clases

[El problema](#) · [Datos](#) · [EDA](#) · [Métricas](#) · [Modelos](#) · [Hiperparámetros](#) · [Modelo final](#) · [Conclusiones](#) · [Hallazgo](#)




El problema y el desbalance de clases

El problema · Datos · EDA · Métricas · Modelos · Hiperparámetros · Modelo final · Conclusiones · Hallazgo



El problema y el desbalance de clases

El problema · Datos · EDA · Métricas · Modelos · Hiperparámetros · Modelo final · Conclusiones · Hallazgo



División de los datos en train y test

El problema · [Datos](#) · EDA · Métricas · Modelos · Hiperparámetros · Modelo final · Conclusiones · Hallazgo

41 176 filas sin duplicados, estratificadas por y

train · 80 %

test · 20 %

ETAPA

DATOS

QUÉ DECIDE

División de los datos en train y test

El problema · [Datos](#) · EDA · Métricas · Modelos · Hiperparámetros · Modelo final · Conclusiones · Hallazgo

41 176 filas sin duplicados, estratificadas por y

train · 80 %

test · 20 %

ETAPA	DATOS	QUÉ DECIDE
análisis de datos	train	qué variables entran, y cómo

División de los datos en train y test

El problema · [Datos](#) · EDA · Métricas · Modelos · Hiperparámetros · Modelo final · Conclusiones · Hallazgo

41 176 filas sin duplicados, estratificadas por y

train · 80 %

test · 20 %

ETAPA	DATOS	QUÉ DECIDE
análisis de datos	train	qué variables entran, y cómo
validación cruzada	train , en 5 folds	modelo e hiperparámetros

División de los datos en train y test

El problema · [Datos](#) · EDA · Métricas · Modelos · Hiperparámetros · Modelo final · Conclusiones · Hallazgo

41 176 filas sin duplicados, estratificadas por y


train · 80 %

test · 20 %

ETAPA	DATOS	QUÉ DECIDE
análisis de datos	train	qué variables entran, y cómo
validación cruzada	train , en 5 folds	modelo e hiperparámetros
evaluación final	test , una sola vez	nada: sólo estima el desempeño


La duración predice el «yes», pero no existe antes de llamar

El problema · Datos · **EDA** · Métricas · Modelos · Hiperparámetros · Modelo final · Conclusiones · Hallazgo



La duración predice el «yes», pero no existe antes de llamar


El problema · Datos · **EDA** · Métricas · Modelos · Hiperparámetros · Modelo final · Conclusiones · Hallazgo



duration: fuera del modelo


El archivo va por fecha: el «yes» sube de 1,9 % a 50,9 %

El problema · Datos · **EDA** · Métricas · Modelos · Hiperparámetros · Modelo final · Conclusiones · Hallazgo



El archivo va por fecha: el «yes» sube de 1,9 % a 50,9 %


El problema · Datos · **EDA** · Métricas · Modelos · Hiperparámetros · Modelo final · Conclusiones · Hallazgo



Partición aleatoria; la época va como limitación


999 no significa «nunca contactado»

El problema · Datos · [EDA](#) · Métricas · Modelos · Hiperparámetros · Modelo final · Conclusiones · Hallazgo



999 no significa «nunca contactado»

El problema · Datos · [EDA](#) · Métricas · Modelos · Hiperparámetros · Modelo final · Conclusiones · Hallazgo



Decisión: pdays se mantiene sin transformar

Todo se ajusta dentro de cada fold, en este orden

El problema · Datos · **EDA** · Métricas · Modelos · Hiperparámetros · Modelo final · Conclusiones · Hallazgo

partición

5 folds barajados


Todo se ajusta dentro de cada fold, en este orden

El problema · Datos · **EDA** · Métricas · Modelos · Hiperparámetros · Modelo final · Conclusiones · Hallazgo




Todo se ajusta dentro de cada fold, en este orden

El problema · Datos · **EDA** · Métricas · Modelos · Hiperparámetros · Modelo final · Conclusiones · Hallazgo




Todo se ajusta dentro de cada fold, en este orden

El problema · Datos · **EDA** · Métricas · Modelos · Hiperparámetros · Modelo final · Conclusiones · Hallazgo



Todo se ajusta dentro de cada fold, en este orden

El problema · Datos · **EDA** · Métricas · Modelos · Hiperparámetros · Modelo final · Conclusiones · Hallazgo



Atípicos por IQR: 6 731 filas marcadas, ninguna eliminada

Dos métricas que no premian decir siempre «no»

El problema · Datos · EDA · **Métricas** · Modelos · Hiperparámetros · Modelo final · Conclusiones · Hallazgo

PARA COMPARAR Y ELEGIR

AUC

¿ordena bien a los clientes?

sin modelo: 0,500

Dos métricas que no premian decir siempre «no»

El problema · Datos · EDA · Métricas · Modelos · Hiperparámetros · Modelo final · Conclusiones · Hallazgo

PARA COMPARAR Y ELEGIR

AUC

¿ordena bien a los clientes?

sin modelo: 0,500

PARA MEDIR EL USO REAL

recall al 20 %

¿qué parte de los «yes» alcanzan las llamadas?

sin modelo: 0,200

Dos métricas que no premian decir siempre «no»

El problema · Datos · EDA · Métricas · Modelos · Hiperparámetros · Modelo final · Conclusiones · Hallazgo

PARA COMPARAR Y ELEGIR

AUC

¿ordena bien a los clientes?

sin modelo: 0,500

PARA MEDIR EL USO REAL

recall al 20 %


¿qué parte de los «yes» alcanzan las llamadas?

sin modelo: 0,200

La exactitud no se usa: decir siempre «no» ya da 88,7 %


Sin ajustar, gana Naïve Bayes: 0,782 contra 0,500 sin modelo

El problema · Datos · EDA · Métricas · **Modelos** · Hiperparámetros · Modelo final · Conclusiones · Hallazgo




Sin ajustar, gana Naïve Bayes: 0,782 contra 0,500 sin modelo

El problema · Datos · EDA · Métricas · **Modelos** · Hiperparámetros · Modelo final · Conclusiones · Hallazgo




¿Desde qué profundidad sobreajusta Random Forest?

El problema · Datos · EDA · Métricas · Modelos · [Hiperparámetros](#) · Modelo final · Conclusiones · Hallazgo




¿Desde qué profundidad sobreajusta Random Forest?

El problema · Datos · EDA · Métricas · Modelos · **Hiperparámetros** · Modelo final · Conclusiones · Hallazgo




¿Desde qué profundidad sobreajusta Random Forest?

El problema · Datos · EDA · Métricas · Modelos · **Hiperparámetros** · Modelo final · Conclusiones · Hallazgo




En KNN sobreajusta el k pequeño: se elige k = 801

El problema · Datos · EDA · Métricas · Modelos · [Hiperparámetros](#) · Modelo final · Conclusiones · Hallazgo




La SVM queda lineal y muy regularizada: $C = 0,001$

El problema · Datos · EDA · Métricas · Modelos · [Hiperparámetros](#) · Modelo final · Conclusiones · Hallazgo




La SVM queda lineal y muy regularizada: $C = 0,001$

El problema · Datos · EDA · Métricas · Modelos · [Hiperparámetros](#) · Modelo final · Conclusiones · Hallazgo




Ajustados, gana Random Forest por 0,011 de AUC en validación

El problema · Datos · EDA · Métricas · Modelos · Hiperparámetros · **Modelo final** · Conclusiones · Hallazgo



Ajustados, gana Random Forest por 0,011 de AUC en validación

El problema · Datos · EDA · Métricas · Modelos · Hiperparámetros · **Modelo final** · Conclusiones · Hallazgo



¿Qué AUC esperar en clientes nuevos de la misma época?

El problema · Datos · EDA · Métricas · Modelos · Hiperparámetros · **Modelo final** · Conclusiones · Hallazgo

0,808

AUC de **test**, sobre 8 236 clientes nuevos · intervalo del 95 %: 0,790–0,824

Matriz de confusión de Random Forest llamando al 20 %

El problema · Datos · EDA · Métricas · Modelos · Hiperparámetros · [Modelo final](#) · Conclusiones · Hallazgo

		test	
		llamando al 20 % de la lista: 1 647 llamadas	
		LLAMADO	NO LLAMADO
«yes»	602 «yes» alcanzados	326 «yes» perdidos	
«no»	1 045 llamadas de más	6 263 bien descartados	

Matriz de confusión de Random Forest llamando al 20 %

El problema · Datos · EDA · Métricas · Modelos · Hiperparámetros · [Modelo final](#) · Conclusiones · Hallazgo

		test	
		llamando al 20 % de la lista: 1 647 llamadas	
		LLAMADO	NO LLAMADO
«yes»	602 «yes» alcanzados	326 «yes» perdidos	
«no»	1 045 llamadas de más	6 263 bien descartados	

- **326 «yes» sin llamar:**
el error más costoso

Matriz de confusión de Random Forest llamando al 20 %

El problema · Datos · EDA · Métricas · Modelos · Hiperparámetros · [Modelo final](#) · Conclusiones · Hallazgo

		test	
		llamando al 20 % de la lista: 1 647 llamadas	
		LLAMADO	NO LLAMADO
«yes»	602 «yes» alcanzados	326 «yes» perdidos	
«no»	1 045 llamadas de más	6 263 bien descartados	

- 326 «yes» sin llamar:
el error más costoso
- recall de test: 0,649

¿Por qué ganó Random Forest y quedó última la SVM?

El problema · Datos · EDA · Métricas · Modelos · Hiperparámetros · Modelo final · [Conclusiones](#) · Hallazgo

Random Forest · **0,795**

no supone escala ni forma; es el que más
pierde sin macro ni month: -0,059

AUC de validación · sin modelo: 0,500

¿Por qué ganó Random Forest y quedó última la SVM?

El problema · Datos · EDA · Métricas · Modelos · Hiperparámetros · Modelo final · Conclusiones · Hallazgo

Random Forest · 0,795

no supone escala ni forma; es el que más pierde sin macro ni month: -0,059

KNN · 0,784

mide distancias: sin escalar, pdays es el 86,6 % de la varianza

AUC de validación · sin modelo: 0,500

¿Por qué ganó Random Forest y quedó última la SVM?

El problema · Datos · EDA · Métricas · Modelos · Hiperparámetros · Modelo final · Conclusiones · Hallazgo

Random Forest · 0,795

no supone escala ni forma; es el que más pierde sin macro ni month: -0,059

Naive Bayes · 0,782

supone independencia: tres macro con r de 0,91 a 0,97

KNN · 0,784

mide distancias: sin escalar, pdays es el 86,6 % de la varianza

AUC de validación · sin modelo: 0,500

¿Por qué ganó Random Forest y quedó última la SVM?

El problema · Datos · EDA · Métricas · Modelos · Hiperparámetros · Modelo final · Conclusiones · Hallazgo

Random Forest · 0,795

no supone escala ni forma; es el que más pierde sin macro ni month: -0,059

Naive Bayes · 0,782

supone independencia: tres macro con r de 0,91 a 0,97

KNN · 0,784

mide distancias: sin escalar, pdays es el 86,6 % de la varianza

SVM · 0,774

quedó lineal: el RBF no la mejora (0,772 en su mejor C)

AUC de validación · sin modelo: 0,500

Limitaciones: el test mide estas campañas, no una futura

El problema · Datos · EDA · Métricas · Modelos · Hiperparámetros · Modelo final · [Conclusiones](#) · Hallazgo

LIMITACIONES

La época: el test es de las mismas campañas

Llamar al 20 % es un supuesto de negocio

Hiperparámetros elegidos con la misma validación

Limitaciones: el test mide estas campañas, no una futura

El problema · Datos · EDA · Métricas · Modelos · Hiperparámetros · Modelo final · [Conclusiones](#) · Hallazgo

LIMITACIONES

La época: el test es de las mismas campañas

Llamar al 20 % es un supuesto de negocio

Hiperparámetros elegidos con la misma validación

QUÉ MEJORARÍAMOS


Validar hacia adelante en el tiempo

Más historial: el 86,3 % no tiene campaña previa

Un costo por tipo de error, no un 20 % fijo


Entrenado con el pasado, Random Forest cae de 0,795 a 0,558

El problema · Datos · EDA · Métricas · Modelos · Hiperparámetros · Modelo final · Conclusiones · [Hallazgo](#)



Entrenado con el pasado, Random Forest cae de 0,795 a 0,558


El problema · Datos · EDA · Métricas · Modelos · Hiperparámetros · Modelo final · Conclusiones · [Hallazgo](#)



Barajado, el AUC es 0,864 entre años distintos y 0,658 dentro del mismo año


En 2008 no sirve; en 2009–2010 pierde, pero no cae al azar

El problema · Datos · EDA · Métricas · Modelos · Hiperparámetros · Modelo final · Conclusiones · [Hallazgo](#)



En 2008 no sirve; en 2009–2010 pierde, pero no cae al azar

El problema · Datos · EDA · Métricas · Modelos · Hiperparámetros · Modelo final · Conclusiones · [Hallazgo](#)



GRACIAS

¿Preguntas?

Grupo 7 — Andrés Cortese (64612) · Sebastián Caules (64331)
Instituto Tecnológico de Buenos Aires — 72.75 Aprendizaje Automático

Trabajo Práctico 2: clasificación supervisada — Defensa: 14/10/2026