

Slides y guion

Defensa del TP2 — Grupo 7

¿Quién va a contratar un plazo fijo? — Trabajo Práctico 2: clasificación supervisada

72.75 Aprendizaje Automático — ITBA — 2026 Q2

Andrés Cortese (64612) · Sebastián Caules (64331)

Defensa: **07/10/2026 (o 14/10)** · 10 + 10 minutos

RELOJ TOTAL

9:00

1 457 palabras a 2,7 por segundo dan 9:00; las ventanas del guion terminan en 9:00. El tope hablado es 9:45. 20 slides en el guion, con 25 **[→]**; el PDF de proyección tiene 45 páginas en la charla y 4 de respaldo.

QUIÉN HABLA

Andrés	725 palabras	4:29	slides 1–3, 8–12 y 18–20
Sebastián	732 palabras	4:31	slides 4–7 y 13–17

CÓMO LEERLO

Cada página es una slide del deck en su **estado final**, con todos los overlays revelados, junto a su texto hablado. Arriba van la ventana de reloj, las palabras, las pulsaciones y la página del PDF, para volver a ella en las preguntas.

Lo que va en letra normal se dice, y la marca **[→]** indica dónde se avanza un overlay. Lo que va en gris cursiva son indicaciones de ensayo, y el bloque «A aclarar» es material para las preguntas: nada de eso se dice en voz alta.

El test todavía no se evaluó (informe/resultados-test.tex): en las slides 14 y 15 va primero la variante con el test cerrado, que es la que muestra la imagen, y debajo, en gris, la de la defensa.

Reloj de ensayo

Slide	Título corto	Empieza	Dura	[→]	Bloque	Quién
1	Portada	0:00	0:05	0	marco	Andrés
2	El problema	0:05	0:30	2	marco	Andrés
3	Qué datos deciden	0:35	0:35	3	teoría	Andrés
4	duration, fuera	1:10	0:25	1	EDA	Sebastián
5	El archivo va por fecha	1:35	0:30	1	EDA	Sebastián
6	El 999 de pdays	2:05	0:25	1	EDA	Sebastián
7	El pipeline y el IQR	2:30	0:35	4	EDA	Sebastián
8	Dos métricas	3:05	0:30	2	teoría	Andrés
9	Modelos sin ajustar	3:35	0:30	0	resultados	Andrés
10	Curva de Random Forest	4:05	0:35	2	resultados	Andrés
11	Curva de KNN	4:40	0:25	0	resultados	Andrés
12	Curva de la SVM	5:05	0:20	1	resultados	Andrés
13	Modelo final	5:25	0:25	0	resultados	Sebastián
14	El test	5:50	0:30	0	resultados	Sebastián
15	Los errores	6:20	0:25	2	resultados	Sebastián
16	Por qué rindió cada uno	6:45	0:40	3	resultados	Sebastián
17	Limitaciones y mejoras	7:25	0:35	1	resultados	Sebastián
18	Hallazgo: la caída	8:00	0:30	1	hallazgo	Andrés
19	Hallazgo: bloque a bloque	8:30	0:25	1	hallazgo	Andrés
20	¿Preguntas?	8:55	0:05	0	marco	Andrés

Puntos de control al ensayar.

- Al terminar la **slide 3** tienen que haber pasado **1:10**: la regla de juego está dicha y todavía no se mostró ningún resultado.
- Al terminar la **slide 7** tienen que haber pasado **3:05**. Es el control más importante: el EDA está cerrado con sus cuatro consecuencias, y todo lo anterior es marco, teoría y datos. Si pasaron más de 3:20, se aplican ya los recortes 3 y 4, que caen en las slides 9 y 11, y se da por hecho el recorte 1. Nunca se recorta en la 10.
- Al terminar la **slide 13** tienen que haber pasado **5:50**: el modelo está elegido y lo que queda del punto 4 es el test. Si pasaron más de 6:05, se aplica el recorte 1; si más de 6:20, también el 2.
- Al terminar la **slide 17** tienen que haber pasado **8:00**: todo lo calificable está dicho (gate G5). Lo que queda es el hallazgo, que es lo mejor del trabajo pero no un punto de la consigna. Si pasaron más de 8:15, el hallazgo va con los recortes 1 y 2.

Orden de recorte, si hay que recortar en vivo. Es un orden de prioridad: lo primero que se sacrifica es lo último que se dice.

1. **Primero, el segundo paso del hallazgo.** En la slide 19, el segundo overlay se reduce a una frase: «Barajado, en esas filas tampoco pasa de 0,584; en 2009–2010 pierde, pero no cae al azar. Por eso el test vale para estas campañas.» De 46 a 24 palabras: unos 8 segundos.
2. **Después, el segundo overlay de la 18:** «Parte del 0,795 es distinguir años: entre años distintos el AUC es 0,864; en los del mismo año, 0,658.» Los dos números están en el veredicto de la pantalla. De 37 a 19 palabras: unos 7 segundos.
3. **En la slide 9, sin el porqué del categórico:** «El mejor es Naive Bayes, en su versión categórica.» El número queda en pantalla y la razón, en las aclaraciones. Unos 7 segundos.
4. **En la slide 11, sin la ponderación por distancia:** se omite «Ponderar por distancia queda peor en todo el rango»; la curva punteada queda en pantalla, y la explicación, en las aclaraciones y en la pregunta 20. Unos 3 segundos.

No se recortan nunca: las limitaciones (slide 17); la slide 3, qué datos deciden (el consejo «Importante»); la 10, sobreajuste y subajuste (pedido por el punto 3.1); la 14, el número de test; y la 15 y la 16, los errores y los supuestos (punto 5). El hallazgo se acorta, pero no se omite: la última slide de contenido tiene que ser una figura (guía A6), y con los recortes 1 y 2 dura de todos modos unos 40 segundos.

La suma (gate G6). Las palabras habladas se cuentan como tokens separados por espacios, sin las marcas [→] ni los signos sueltos, y cada «?» del test cuenta como una palabra; en las slides 14 y 15 cuenta la variante más larga. Aplicada al guion del TP1, esta cuenta da 1 606 palabras, 26 menos (el 1,6 %) que las 1 632 que declaran sus 22 encabezados: siete coinciden y los otros quince declaran entre 1 y 4 palabras de más. Contado con esta regla, el TP1 dice 1 606 palabras en los 10:00 de su reloj, 2,68 por segundo: redondeado, el mismo 2,7.

- **1 457 palabras / 2,7 = 539,6 s = 9:00 ± 9:45.** Pasa, con 45 segundos de margen. Con las ventanas redondeadas a 5 segundos, el reloj termina en 9:00, 15 segundos antes que el esqueleto del plan. A 2,68 por segundo, 9:04.
- **Con los números leídos completos: entre 9:23 y 9:28.** Los números de este guion tardan más en decirse que los del TP1, porque muchos son AUC con tres decimales. Se expandió cada número escrito con cifras a las palabras con que se lee («0,795» son seis: «cero coma setecientos noventa y cinco»), y cada «?» del test, como un número de tres decimales: cada palabra de este guion equivale a 1,19 palabras leídas, y cada una del TP1, a 1,15. A la velocidad de lectura que 2,7 por segundo le supone al TP1, este guion dura 9:23; si el TP1 se dijo en los 10:00 de su reloj, 9:28, 17 segundos por debajo del tope. Hay 85 números hablados, el 5,8 % de las palabras (en el TP1, 93, también el 5,8 %).
- **Lo que decide son los dos ensayos cronometrados** (paso 8.4 del plan, gate G6): tienen que durar 10:00 o menos. Si un ensayo pasa de 9:45, se aplica el orden de recorte de arriba, en ese orden.

TRABAJO PRÁCTICO 2: CLASIFICACIÓN SUPERVISADA

¿Quién va a contratar un plazo fijo?

Grupo 7 — Andrés Cortese (64612) · Sebastián Caules (64331)
Instituto Tecnológico de Buenos Aires — 72.75 Aprendizaje Automático

Dataset: *Bank Marketing* — 41 188 contactos de campañas telefónicas de un banco, de 2008 a 2010
Defensa: 07/10/2026

1/20

(bloque 1, slides 1–3).

Buenas tardes. Grupo siete: Trabajo Práctico dos, clasificación supervisada sobre *Bank Marketing*.

A ACLARAR • PREGUNTAS PROBABLES

- **El dataset es el del enunciado** (TP2, p. 1): el *Bank Marketing* de UCI con los indicadores macroeconómicos; 41 188 filas, 20 predictoras y la clase y, con campañas de mayo de 2008 a noviembre de 2010 (*bank-additional-names.txt*). El 41 188 de la portada es el archivo entero; todo lo que sigue sale de train, salvo que se diga otra cosa.
- **Los cuatro clasificadores son de scikit-learn**, como pide el punto 2.1.


2 · Decir siempre «no» ya acierta el 88,7 %

0:05 → 0:35 · ~87 palabras · 2 [→] · página 4 del PDF

Habla: Andrés

Decir siempre «no» ya acierta el 88,7 %

[El problema](#) · [Datos](#) · [EDA](#) · [Métricas](#) · [Modelos](#) · [Hiperparámetros](#) · [Modelo final](#) · [Conclusiones](#) · [Hallazgo](#)



EL PROBLEMA

2/20

Un banco ofrece un plazo fijo por teléfono. Antes de marcar, ¿este cliente va a contratar? Si lo sabemos, llamamos primero a los más probables.

[→] El modelo sólo puede usar lo que el banco sabe antes de la llamada: el cliente, su historial en campañas anteriores, el contexto económico y los datos de la llamada que va a hacer.

[→] Y la clase está muy desbalanceada: en train, sólo el 11,3 % dijo que sí. Decir siempre «no» ya acierta el 88,7 %, así que aquí la exactitud no sirve.

A ACLARAR · PREGUNTAS PROBABLES

- **Cuántos son, en train:** 3 711 «yes» de 32 940 filas; 7,9 «no» por cada «yes».
- **Por qué 19 predictoras y no 20.** Sale *duration*, que es fuga (slide 4; D-05). Las otras 19 se revisaron una por una y existen antes de marcar (D-07).
- **¿campaign existe antes de llamar?** Sí: es el número de llamada que se va a hacer, contando esa (*bank-additional-names.txt*, atributo 12). La reserva es que cada fila guarda el total al cierre de la campaña y, tras un «yes», no se vuelve a llamar (inferencia), así que su valor final depende en parte del resultado. En train, la media es 2,053 en los «yes» y 2,627 en los «no», con la misma mediana, 2: compatible con esa inferencia, pero no la prueba. Va como limitación (D-07).
- **¿month, day_of_week y contact?** Son de la llamada que se va a hacer y se eligen antes de marcar (inferencia; es la consulta 2 a la cátedra).
- **Por qué el modelo ordena en lugar de clasificar con un umbral.** El enunciado habla de «priorizar recursos de marketing» (TP2, p. 1): lo que el banco necesita es a quién llamar primero.
- **La exactitud engaña con clases desbalanceadas:** modelos con la misma exactitud cometen errores muy distintos (Clase 4, slides 26–27; D-19).

3 · Train decide; test sólo mide, y una sola vez

0:35 → 1:10 · punto de control · ~92 palabras · 3 [→] · página 8 del PDF

Habla: Andrés

Train decide; test sólo mide, y una sola vez

El problema · Datos · EDA · Métricas · Modelos · Hiperparámetros · Modelo final · Conclusiones · Hallazgo

41 176 filas: las 41 188 del archivo menos 12 duplicados exactos · 80/20 estratificado por y

train	test
32 940 filas · 80 %	8 236 filas · 20 %

ETAPA	DATOS	QUÉ DECIDE
EDA y ablaciones	train	qué variables entran, y cómo
validación cruzada	train , en 5 folds	modelo e hiperparámetros
evaluación final	test , una sola vez	nada: sólo estima el desempeño

DATOS

3/20

Es la regla de juego antes del primer número (guía A3) y el consejo «Importante» del enunciado. Se dice completa pero rápido: son definiciones que el tribunal ya conoce. El segundo paso cuenta, sin esconderla, la primera exploración sobre el archivo completo (D-04).

Primero, quitamos 12 duplicados exactos: si una copia cae en train y otra en test, el test deja de ser independiente. Después, 80/20 estratificado por la clase.

[→] El análisis exploratorio que decide y las ablaciones leen sólo train: una primera exploración usó el archivo completo, y la rehicimos sobre train antes de decidir nada.

[→] La validación cruzada de 5 folds, también: con ella elegimos modelo e hiperparámetros.

[→] Y el test no decide nada: se abre una vez, al final, para estimar el desempeño. Por eso cada número dice de qué conjunto sale.

A ACLARAR · PREGUNTAS PROBABLES

- **Las cifras de la partición:** 41 176 filas sin duplicados (D-01; ningún par duplicado tiene etiquetas distintas); train 32 940 filas (80 %) y test 8 236 (20 %), con semilla 42 (D-02).
- **¿Por qué estratificar, si no se vio en clase?** Sin estratificar, la proporción de «yes» del test cambia con la semilla: en 400 particiones con semillas distintas, su desvío es de 0,31 puntos, entre 10,4 % y 12,1 %. Estratificando, train y test quedan con el mismo 11,3 % (D-02). La cifra sale de `src/evidencia_particion.py`, que mide la partición y no elige nada del modelo.
- **¿Qué exploración corrió sobre el archivo completo?** La primera versión del análisis exploratorio, en el estado inicial del repositorio (commit `0a9b311`), cuyo resumen dejaba las decisiones como pendientes. Se rehízo sobre train, con `src/eda.py`, en el commit siguiente (`108ff99`), el mismo que registra las primeras decisiones: antes de tomar ninguna (D-04).
- **¿Cómo se garantiza que nada mire el test?** Todo lo anterior al punto 4 lee sólo train con `cargar_train()`. El único módulo que evalúa un modelo en test es `src/evaluar_test.py`; otros cuatro archivos pueden nombrar el test o el CSV completo, y ninguno elige nada del modelo: la partición, su verificación, la medición de la partición misma y el propio test de aislamiento. `tests/test_aislamiento.py` falla si cualquier otro `.py` los nombra (D-04; pregunta 2).
- **El tamaño de cada vuelta de la validación cruzada, dentro de train:** 26 352 filas para ajustar y 6 588 para validar.
- **Qué se evalúa en test:** Random Forest reentrenado con todo train, que es lo que pide la cátedra una vez elegido el modelo (Clase 2, slides 88–89).
- **El orden importa** porque el enunciado lo pide: partir «antes de aplicar cualquier transformación que pueda producir data leakage» (TP2, p. 1).


4 · La duración predice el «yes», pero no existe antes de llamar

1:10 → 1:35 · ~66 palabras · 1 [→] · página 10 del PDF

Habla: Sebastián

La duración predice el «yes», pero no existe antes de llamar

El problema · Datos · EDA · Métricas · Modelos · Hiperparámetros · Modelo final · Conclusiones · Hallazgo



duration: fuera del modelo

EDA

4/20

(bloque 2, slides 4–7). Entra con la primera decisión del EDA.

Primera decisión del análisis exploratorio: la fuga. *duration* es la duración de la última llamada: se conoce al colgar, cuando el resultado ya se sabe. Medimos cuánto pesa, en validación: con *duration* los cuatro saltan, y Random Forest pasa de 0,770 a 0,939. Es un techo que no existe antes de llamar, y el propio diccionario del dataset pide descartarla.

[→] Consecuencia: *duration* queda fuera del modelo.

A ACLARAR · PREGUNTAS PROBABLES

- **Con qué modelos se midió.** Con la configuración de referencia de las ablaciones (A0: Naive Bayes gaussiano, SVM con RBF y $C = 1$, KNN con $k = 15$, Random Forest de 300 árboles), en los mismos 5 folds: es la ablación A1. Los cuatro saltos, en AUC de validación: NB gaussiano de 0,768 a 0,831, SVM de 0,701 a 0,907, KNN de 0,755 a 0,911 y RF de 0,770 a 0,939 (+0,170).
- **¿Sola, cuánto da?** Como puntaje, sin ajustar nada, *duration* da AUC 0,818 sobre train.
- **Cuánto predice, en train** (la figura sólo muestra el AUC, así que no se dice): el decilo más corto llega a 59 segundos y tiene 0,0 % de «yes»; el más largo empieza en 551 segundos y tiene 46,1 %. Las 4 filas con *duration* = 0 son todas «no».
- **El diccionario lo dice textual:** *duration* sólo sirve como referencia y hay que descartarla para un modelo predictivo realista (bank-additional-names.txt, atributo 11; D-05).
- **¿Qué otras variables se revisaron por fuga?** Las 20, una por una: 19 existen antes de marcar, y campaign con la reserva de la slide 2 (D-07).
- **¿Por qué medirla, si de todos modos sale?** Porque el enunciado sugiere comparar el modelo con y sin las variables problemáticas (TP2, p. 1), y porque el techo dice cuánto cuesta no tenerla.


5 · El archivo va por fecha: el «yes» sube de 1,9 % a 50,9 %

1:35 → 2:05 · ~79 palabras · 1 [→] · página 12 del PDF

Habla: Sebastián

El archivo va por fecha: el «yes» sube de 1,9 % a 50,9 %

El problema · Datos · EDA · Métricas · Modelos · Hiperparámetros · Modelo final · Conclusiones · Hallazgo



Partición aleatoria; la época va como limitación

EDA

5/20

Segunda: el archivo está ordenado por fecha, de mayo de 2008 a noviembre de 2010, y la tasa de «yes» no es estable. En train, en bloques de 2 000 filas, sube de 1,9 % a 50,9 %, mientras el euríbor se desploma.

[→] Consecuencia: partimos al azar —el enunciado plantea k-fold y no menciona el tiempo— y barajamos los folds, para que ninguno quede en una sola época. Lo que eso cuesta va como limitación, y es el hallazgo del final.

A ACLARAR · PREGUNTAS PROBABLES

- **Por año, en train:** 4,9 % de «yes» en 2008, 19,2 % en 2009 y 51,9 % en 2010, 10,5 veces más. Por bloques, el último tiene 27,1 veces la tasa del primero.
- **El euríbor, en train:** 4,86 de media en el primer bloque y 0,71 en el más bajo (panel inferior de la figura).
- **¿De dónde sale el año?** El CSV no lo trae: cada vez que el mes retrocede, empieza un año nuevo (año inferido, como en [resultados/eda/eda.html](https://resultados.eda/eda.html)).
- **¿Por qué no partir por fecha?** El enunciado plantea k-fold y no menciona el tiempo, y con el último 20 % del archivo como test se entrenaría en una época y se evaluaría en otra: train tendría 6,4 % de «yes» y test 30,8 % (D-03). Es la consulta 5 a la cátedra.
- **¿Qué pasaba sin barajar?** StratifiedKFold sin barajar, que es lo que hace pasarle un número a cv, deja cada fold en una época: en train, euríbor medio de 4,87 en el primero y 1,10 en el último; barajando, todos entre 3,58 y 3,64 (D-06).
- **month también fecha las filas:** en train, el 100,0 % de las de septiembre, el 90,9 % de las de octubre y el 94,5 % de las de diciembre caen en el último 20 % por fecha. Por eso la ablación A8 saca el bloque macro y month (slides 18–19).


6 · 999 no significa «nunca contactado»

2:05 → 2:30 · ~67 palabras · 1 [→] · página 14 del PDF

Habla: **Sebastián**

999 no significa «nunca contactado»

El problema · Datos · **EDA** · Métricas · Modelos · Hiperparámetros · Modelo final · Conclusiones · Hallazgo



pdays se queda: el 999 es un corte, no un número

EDA

6/20

Tercera: pdays. El diccionario dice que 999 es «no contactado antes», y es el 96,3 % de train. Pero 3 302 filas con 999 sí tuvieron contactos previos, y los que tienen días registrados contratan el 64,6 %.

[→] En validación, sacarla empeora a Naive Bayes y a KNN, y en los otros dos no cambia nada. Se queda: escalado o en un árbol, el 999 funciona como un corte.

A ACLARAR · PREGUNTAS PROBABLES

- **¿Cuánto empeora sin pdays?** En AUC de validación, pareado por fold (ablación A2): NB gaussiano -0,0012 con desvío 0,0003, y KNN -0,0019 con desvío 0,0007: más que su desvío. SVM +0,0023 (desvío 0,0037) y RF +0,0003 (desvío 0,0022): neutros (D-10).
- **Cuántos tienen días registrados:** 1 207 filas de train con pdays < 999. Entre los que tienen 999, el «yes» es 9,2 %.
- **La barra del medio** (999 con contactos previos) tiene su tasa anotada en la figura, pero esa tasa no es un macro de numeros.md: se señala en pantalla, no se dicta.
- **¿Y una indicadora de contacto previo?** Ya está: poutcome «nonexistent» equivale a previous = 0, y duplicarla pesaría doble en Naive Bayes y en las distancias de KNN (D-10).
- **¿Y el historial, sirve?** Con poutcome = success, en train el «yes» es 66,0 %.
- **Esas 1 207 filas son justo los atípicos de pdays por IQR:** por eso no se borran (slide 7).


7 · Todo se ajusta dentro de cada fold, en este orden

2:30 → 3:05 · punto de control · ~101 palabras · 4 [→] · página 19 del PDF

Habla: Sebastián

Todo se ajusta dentro de cada fold, en este orden

El problema · Datos · EDA · Métricas · Modelos · Hiperparámetros · Modelo final · Conclusiones · Hallazgo



Atípicos por IQR: 6 731 filas marcadas, ninguna eliminada

EDA

7/20

Las cajas entran en el orden en que el pipeline las ejecuta. El último overlay es la consecuencia del IQR, que es exactamente lo que la cátedra marcó como inconcluso en el TP1: se dice para qué sirvió, con su número, y que no se borró nada.

La partición: 5 folds estratificados y barajados, para que cada uno mezcle las épocas.

[→] Dentro de cada fold, reglas fijas: sale `duration`, `default` pasa a indicadora, se funden dos categorías raras y `unknown` queda como categoría; quedan 58 columnas.

[→] Después, la codificación de cada modelo: escalado para KNN y la SVM, deciles para Naive Bayes, ajustados sólo con el fold de entrenamiento.

[→] Los cuatro, en los mismos folds.

[→] Y los atípicos por IQR: sirven para diagnosticar, no para filtrar. Marcan 6 731 filas de train, y entre los de `pdays` el 64,6 % dijo que sí: son señal, no se borra ninguna.

A ACLARAR · PREGUNTAS PROBABLES

- **¿Por qué `default` como indicadora?** En train sólo 2 filas dicen «yes» (D-09). Mejora a RF en +0,0029 de AUC de validación (desvío 0,0021; ablación A3), es neutra en los otros tres, y pasa de 62 a 60 columnas.
- **Las categorías raras** (D-11): `illiterate` se funde con `basic.4y`, y `marital «unknown»` con `married`, la moda. Es neutra o levemente mejor (NB gaussiano +0,0008 de AUC de validación; ablación A4) y simplifica. Con las dos, 58 columnas.
- **¿Y Random Forest?** One-hot sin escalar: no mide distancias (D-12). **¿Y Naive Bayes?** El categórico: las numéricas en 10 cortes por deciles aprendidos en cada fold, las categóricas como códigos, y Laplace con $\alpha = 1$ (Clase 6, slide 46; D-18); para qué sirve, pregunta 16.
- **¿Cómo se decidió cada paso?** Con doce ablaciones, cada una con y sin una sola decisión, en los mismos folds; se adopta lo que sube el AUC de validación más que su desvío, o lo neutro que simplifica (respaldo R3; la A1 es la de la slide 4).
- **Los atípicos, completos** (D-17, en train): 6 731 filas, el 20,4 %, tienen algún valor fuera de 1,5·IQR. El «yes» entre los atípicos de `pdays` es 64,6 %; de `age`, 46,5 %; de `previous`, 26,6 %; y de `campaign`, 4,5 %, contra 11,3 % en total. Borrarlos sacaría a los que más contratan.
- **¿Y unknown?** Queda como categoría (D-08): imputar por la moda es neutro (RF +0,0011 en validación) y borra una señal: en train, con `default «unknown»` el «yes» es 5,3 %, contra 12,8 % cuando se conoce.
- **¿KNN sin escalar no da más?** Sí: +0,0084 de AUC de validación (desvío 0,0067), pero por la razón equivocada; es la pregunta 8 del banco (D-12).
- **campaign y la edad, sin transformar** (AUC de validación): `log1p` sobre `campaign` es nulo (A5: KNN +0,0008, SVM -0,0006; D-13), y la edad en tramos suma columnas (70) sin mejorar al NB gaussiano (A10: +0,0001; D-16).
- **Sin fuga por construcción:** todo lo aprendido vive dentro del Pipeline y se vuelve a ajustar en cada fold, que es lo que pide el enunciado (TP2, p. 1); lo verifica `tests/test_preproceso.py`.

8 · Dos métricas que no premian decir siempre «no»

3:05 → 3:35 · ~83 palabras · 2 [→] · página 22 del PDF

Habla: Andrés

Dos métricas que no premian decir siempre «no»

El problema · Datos · EDA · Métricas · Modelos · Hiperparámetros · Modelo final · Conclusiones · Hallazgo

PARA COMPARAR Y ELEGIR

AUC

¿ordena bien a los clientes?

sin modelo: 0,500

PARA MEDIR EL USO REAL

recall al 20 %

¿qué parte de los «yes» alcanzan las llamadas?

sin modelo: 0,200

La exactitud no se usa: decir siempre «no» ya da 88,7 %

MÉTRICAS

8/20

(bloque 3, slides 8–12). Es teoría de la Clase 4: se nombra, no se desarrolla. Lo propio es el 20 % y por qué no se usa la exactitud.

Falta la vara: dos métricas de la Clase 4. El AUC mide si el modelo ordena bien a quién llamar, sin depender de un umbral; sin modelo vale 0,5. Con ella comparamos y elegimos, siempre en validación.

[→] La segunda es el uso real: si el banco llama al 20 % de la lista con mayor puntaje, ¿qué parte de los que contratarían alcanza? Cuenta el error caro, el cliente perdido; sin modelo vale 0,200.

[→] La exactitud, no: decir siempre «no» ya da el 88,7 %.


A ACLARAR · PREGUNTAS PROBABLES

- **Las citas:** el AUC, Clase 4, slides 45–51; el umbral «depende del costo de cada error», slides 41–44; tres modelos con la misma exactitud cometen errores distintos, slides 26–27; precisión y recall, slides 30–31 (D-19).
- **Lo que el AUC no hace:** no premia decir siempre «no» (un puntaje constante da 0,5) y no depende del umbral. Por eso sirve para ordenar a quién llamar, que es priorizar recursos (TP2, p. 1).
- **«Sin modelo»** es un `DummyClassifier` que les da a todos el mismo puntaje, medido en los mismos folds de validación: AUC 0,500 y recall 0,200, porque llamar al 20 % al azar alcanza al 20 % de los «yes». Es el único rótulo de la línea de base en todo el TP.
- **¿Por qué no el umbral de la Clase 4, el punto de la ROC más cercano a (0,1)** (slide 52)? Es simétrico entre los dos errores, y aquí no cuestan lo mismo; y con un umbral por modelo los recalls no se comparan. Con el presupuesto, todos hacen las mismas llamadas: 1 318 por fold de validación (D-20). En test serán 1 647.
- **¿Por qué el 20 %?** Es un supuesto de negocio, declarado (D-20). Con el 10 % o el 30 %, Random Forest sigue primero en validación (respaldo R2; pregunta 9).
- **¿Y F_1 ?** Se guarda de todos modos: en validación, RF 0,454 y sin modelo 0,144. Es la consulta 1 a la cátedra; si la acepta, cambia qué columna se lee, no qué se corre.
- **¿Y la precisión?** Se calcula, pero no decide: en validación, sin modelo es 0,113, la tasa de «yes».
- **¿Y el desbalance?** No se remuestrea: estas dos métricas ya no premian el «no» (D-21; pregunta 10).
- **Los empates en el corte** se reparten en proporción (`src/metricas.py`, `en_presupuesto`).

9 · Sin ajustar, gana Naive Bayes: 0,782 contra 0,500 sin modelo

3:35 → 4:05 · ~74 palabras · sin [→] · página 23 del PDF

Habla: Andrés



Son tres los que sobreajustan: también KNN con $k = 15$, que es el puente a la slide 11, donde sobreajusta el k pequeño.

Primero, los modelos con hiperparámetros de referencia: en AUC de validación, todos quedan muy por encima de sin modelo. El mejor es Naive Bayes en su versión categórica: discretizar las numéricas en deciles le suma 0,013 sobre el gaussiano, porque las numéricas están lejos de ser normales. Y tres sobreajustan: Random Forest sin límite de profundidad, la SVM con RBF y KNN con $k = 15$. Lo muestran, y lo corrigen, las curvas que siguen.

A ACLARAR · PREGUNTAS PROBABLES

- **La referencia:** Random Forest de 300 árboles sin límite de profundidad; KNN con $k = 15$; SVM con RBF y $C = 1$; Naive Bayes con 10 cortes y Laplace $\alpha = 1$ (Clase 6, slide 46; pregunta 16).
- **Categórico contra gaussiano** (D-18), en validación: $0,782 \pm 0,007$ contra $0,769 \pm 0,009$; fold a fold, $+0,013 \pm 0,0024$, entre $+0,010$ y $+0,016$: gana en los cinco. En recall al 20 %, $+0,048$.
- **«Están lejos de ser normales», en train:** pdays es casi binaria por el centinela (999 en el 96,3 % de las filas), campaign tiene cola larga (asimetría 4,89, máximo 56) y la edad forma una U (D-18).
- **¿Por qué RF da 0,770 en la slide 4 y 0,772 aquí?** Los dos son AUC de validación, pero la 4 es la referencia de las ablaciones (A0), antes de adoptar A3 y A4; aquí ya están. Lo mismo la SVM (0,701 y 0,702) y el NB gaussiano (0,768 y 0,769); KNN da 0,755 en las dos.
- **Las brechas train - validación** (la figura sólo muestra validación, así que no se dicen): RF, train 1,000 y brecha 0,228; SVM con RBF, train 0,901 y brecha 0,200; KNN con $k = 15$, train 0,871 y brecha 0,116; NB categórico, 0,001. Las curvas de las slides 10 a 12 muestran cada sobreajuste.
- **Cuánto es «muy por encima»:** el mejor supera a sin modelo por 0,282 de AUC de validación.


10 · ¿Desde qué profundidad sobreajusta Random Forest?

4:05 → 4:40 · ~98 palabras · 2 [→] · página 26 del PDF

Habla: Andrés

¿Desde qué profundidad sobreajusta Random Forest?

El problema · Datos · EDA · Métricas · Modelos · **Hiperparámetros** · Modelo final · Conclusiones · Hallazgo



HIPERPARÁMETROS

10/20

Es el punto 3.1 que el enunciado pide decir en la presentación: sobreajuste y subajuste en una curva. Tres pasos, con el mismo encuadre: no apurarla.

Esta es la curva para discutir sobreajuste: la profundidad máxima de los árboles. En train el AUC sube siempre, y sin límite llega a 1,000: los árboles memorizan.

[→] La validación, en cambio, sube hasta profundidad 10 y después baja, hasta 0,772 sin límite: la brecha se abre a 0,228. Eso es sobreajuste. En el otro extremo, con profundidad 2, train y validación casi empatan, y los dos quedan bajos: el modelo es demasiado simple, subajuste.

[→] Elegimos 8: queda dentro de un error estándar del máximo y es más simple. En validación da 0,795, con una brecha de 0,030.

A ACLARAR · PREGUNTAS PROBABLES

- **¿Por qué no 10, si es el máximo?** En AUC de validación, 0,797 contra 0,795: la diferencia es menor que un error estándar del mejor, 0,0029. Quedan dentro 8, 10 y 12 (el umbral es 0,7939), y entre ellos la regla elige el más simple (D-22).
- **¿Y por qué no la profundidad seis?** Con cuatro decimales, en validación, la de seis da 0,7936 y el umbral es 0,7939: queda fuera por 0,0003, y 8 es el más simple de los que quedan dentro. Es por poco, pero la regla se aplica tal cual. A tres decimales la de seis se lee 0,794 y parece entrar: por eso se dice con cuatro. La banda de la figura es ± 1 desvío entre folds, no el error estándar, que es ese desvío dividido por la raíz de 5; el umbral no está dibujado, y a simple vista la de seis parece adentro.
- **¿De dónde sale la regla?** No está en las slides de la cátedra. La Clase 3 advierte que elegir el mejor entre muchas estimaciones con ruido también elige ruido favorable (slides 98–100), y la regla lo atenúa porque no elige el máximo (D-22). Viene de los árboles CART de Breiman y otros, y está en Hastie, Tibshirani y Friedman, *The Elements of Statistical Learning*, §7.10.1: fuera de la bibliografía de la materia. También la usamos en el TP1.
- **El protocolo** es el de la Clase 7, slide 50: el AUC en train y en validación con los 5 folds, la brecha entre los dos y la curva.
- **La curva se midió con 300 árboles**, los de la referencia; el modelo final tiene 200, y con profundidad 8 da el mismo 0,795 de validación.
- **¿Y el número de árboles?** 200 (N0-11). Con profundidad 8 la curva de validación es plana: 25 árboles dan 0,793 y 800 dan 0,796, y la regla elegía 25. Pero más árboles no suman complejidad: no cambian el sesgo y sólo bajan la varianza (Clase 7, slide 61). Es la pregunta 12 del banco.
- **¿Pesos de clase?** +0,0006 de AUC de validación; fold a fold, la diferencia es $+0,0006 \pm 0,0009$, positiva en los 5 folds, pero despreciable por su tamaño (N0-12). Pregunta 13.
- **El subajuste, en números:** con profundidad 2, train 0,783 y validación 0,782, brecha 0,001; los dos por debajo del 0,795 que la validación alcanza con 8.
- **Otros puntos de validación** (la figura los tiene todos): profundidad 4, 0,789; 12, 0,795; 15, 0,793; 20, 0,784; 25, 0,776.


11 · En KNN sobreajusta el k pequeño: se elige k = 801

4:40 → 5:05 · ~62 palabras · sin [→] · página 27 del PDF

Habla: Andrés

En KNN sobreajusta el k pequeño: se elige k = 801

El problema · Datos · EDA · Métricas · Modelos · **Hiperparámetros** · Modelo final · Conclusiones · Hallazgo



HIPERPARÁMETROS

11/20

En KNN el eje va al revés. Con un vecino, train da 0,988 y validación 0,619: cada cliente es su propio vecino, sobreajuste puro. Al sumar vecinos la brecha se cierra, y desde 151 todo queda dentro de un error estándar del mejor; tomamos el más suave, 801, con una brecha de 0,006. Ponderar por distancia queda peor en todo el rango.

A ACLARAR · PREGUNTAS PROBABLES

- **El elegido, en validación:** k = 801 da 0,784, anotado en la figura con su brecha.
- **¿Dónde está el máximo?** En k = 601, también con 0,784 de AUC de validación; la curva es una meseta desde 301. El umbral de un error estándar es 0,7806 (error estándar del mejor, 0,0037).
- **¿No es enorme k = 801?** Cada fold entrena con 26 352 filas y el «yes» es el 11,3 % de train: estimar bien una proporción baja pide muchos vecinos (inferencia). Y está en el borde de la grilla a propósito: pregunta 21.
- **¿Y ponderar por distancia?** (Mitchell §8.2.1). Con weights = distance, train da 1,000, porque cada punto de train se encuentra a sí mismo, y validación 0,770 con k = 801, el que elige la misma regla: brecha 0,230. Con más de un vecino queda por debajo de la uniforme en todo el rango (con uno, las dos coinciden).
- **La brecha con un vecino es 0,369.** El eje es logarítmico porque la grilla va de 1 a 801.
- **¿Por qué train da 0,988 y no 1,000 con un vecino?** Porque en train hay filas con las mismas 19 predictoras y distinta respuesta: a distancia cero, el vecino de una puede ser su gemela con la otra clase. En train, 156 combinaciones de las 19 predictoras aparecen con «yes» y con «no», en 350 filas (pregunta 7).
- **Escalar no es opcional en KNN:** mide distancias (Clase 8, slide 54; Alpaydin §8.3, p. 192).


12 · La SVM queda lineal y muy regularizada: $C = 0,001$

5:05 → 5:25 · ~62 palabras · 1 [→] · página 29 del PDF

Habla: Andrés

La SVM queda lineal y muy regularizada: $C = 0,001$

El problema · Datos · EDA · Métricas · Modelos · **Hiperparámetros** · Modelo final · Conclusiones · Hallazgo



HIPERPARÁMETROS

12/20

En la SVM exploramos C y el kernel, con pesos balanceados, que aquí sí ayudan. Con kernel lineal la curva de C es plana, sin sobreajuste, y tomamos 0,001, el más regularizado.

[→] Con RBF, en cambio, un C grande sobreajusta: train sube casi a uno y la validación cae. Y ni en su mejor C el RBF supera al lineal: queda lineal.

A ACLARAR · PREGUNTAS PROBABLES

- **¿Qué es C ?** La convención de scikit-learn: un C grande castiga más las violaciones del margen y regulariza menos (Clase 8, slide 49). Pregunta 17.
- **Los kernels con $C = 0,001$,** en validación: lineal 0,774, polinómico 0,774 y RBF 0,768. Empatar no alcanza para elegir el polinómico: el lineal es más simple.
- **Los pesos** (no están en la figura, así que no se dicen): con RBF y $C = 1$, balancear lleva el AUC de validación de 0,702 a 0,770; fold a fold, la diferencia es $+0,068 \pm 0,011$, positiva en los 5 folds (D-21). Cambian el orden, no sólo el umbral: pregunta 10.
- **¿Por qué LinearSVC?** La SVM lineal de libsvm con $C = 10$ no terminó en 600 segundos (D-22). LinearSVC con pérdida *hinge* es la misma SVM lineal de margen blando, sin kernel, resuelta con liblinear en lugar de libsvm; lo único que cambia es que liblinear también regulariza el término independiente.
- **Con kernel lineal, 0,001 y 0,01 empatan** en 0,774 de validación: se toma el más regularizado. La brecha queda en 0,002. 0,001 es el menor C de la grilla: pregunta 21.
- **El mejor RBF**, en AUC de validación, es $C = 0,01$ con pesos, 0,772; sin pesos, $C = 0,1$, 0,706.
- **¿En la figura el RBF no queda por encima del lineal?** Entre $C = 0,1$ y 1, apenas, comparados en el mismo C ; pero su máximo de validación, 0,772, no alcanza el 0,774 del lineal elegido.
- **¿Y γ ?** No se ajustó: el kernel final es lineal. La grilla conjunta de C y γ (Clase 8, slides 48–49) quedó como opcional.


13 · Ajustados, gana Random Forest por 0,011 de AUC en validación

5:25 → 5:50 · punto de control · ~60 palabras · sin [→] · página 30 del PDF

Habla: Sebastián

Ajustados, gana Random Forest por 0,011 de AUC en validación

El problema · Datos · EDA · Métricas · Modelos · Hiperparámetros · **Modelo final** · Conclusiones · Hallazgo



MODELO FINAL

13/20

(bloque 4, slides 13–17). Entra con el resultado de la selección.

Con los hiperparámetros elegidos gana Random Forest: en validación, 0,795 de AUC y 0,629 de recall llamando al 20 %. Le siguen KNN, Naive Bayes y la SVM, en ese orden, y ninguno queda dentro de un error estándar de Random Forest. Pero importa la escala: entre el mejor y el peor hay 0,021; entre Random Forest y sin modelo, 0,295.

A ACLARAR · PREGUNTAS PROBABLES

- **Los cuatro, en AUC de validación** (anotados en la figura): Random Forest 0,795, KNN 0,784, Naive Bayes 0,782 y SVM 0,774.
- **El umbral de empate:** 0,7927, que es el AUC de validación de Random Forest menos su error estándar, 0,0025 (D-23). No entra ninguno, así que decide el AUC solo; si hubiera empate, desempataba el recall.
- **¿Sobreajusta?** Brecha de 0,030: train 0,825 y validación 0,795.
- **Los desvíos entre folds de validación** de Random Forest: $\pm 0,006$ en AUC y $\pm 0,018$ en recall.
- **Los recalls de los otros tres**, en validación: KNN 0,617, Naive Bayes 0,614 y SVM 0,614.
- **¿Cuánto sumó ajustar?** En AUC de validación: Random Forest +0,023, KNN +0,029 y SVM +0,072.
- **¿Y la precisión?** Llamando al 20 %, Random Forest acierta 0,354 de las llamadas; sin modelo, 0,113 (validación).

14 · ¿Qué AUC esperar en clientes nuevos de la misma época?

5:50 → 6:20 · ~80 palabras · sin [→] · página 31 del PDF

Habla: Sebastián

¿Qué AUC esperar en clientes nuevos de la misma época?

[El problema](#) · [Datos](#) · [EDA](#) · [Métricas](#) · [Modelos](#) · [Hiperparámetros](#) · [Modelo final](#) · [Conclusiones](#) · [Hallazgo](#)

AUC DE TEST

pendiente: se evalúa una vez, después del 30/09

MODELO FINAL

14/20

Es la única slide que no compara nada (guía C2, C3): ni «sin modelo» ni otro modelo, ni en pantalla ni en voz alta. La comparación con validación se dice, no se proyecta (C6). Los «?» se leen de *informe/numeros.md*, sección «Números de test», después de evaluar.

MIENTRAS EL TEST SIGA CERRADO (ensayos hasta el 01/10), en lugar de la variante de abajo, en gris:

¿Qué esperar en clientes nuevos? Lo va a decir el test: Random Forest reentrenado con todo train, sobre las 8 236 filas de test, una sola vez. Todavía no lo abrimos: lo haremos después de las respuestas de la cátedra. Y atención a qué va a medir: el test sale de las mismas campañas que train, así que estima clientes nuevos de esa época, no una campaña futura. Eso es el hallazgo.

Con el test evaluado, en la defensa, en lugar de lo anterior:

¿Qué esperar en clientes nuevos? Lo dice el test: Random Forest reentrenado con todo train, sobre las 8 236 filas de test, una sola vez. Da ? de AUC, con un intervalo del 95 % de ?. Contra validación, la diferencia es ?, frente a un desvío entre folds de 0,006. Y atención a qué mide: el test sale de las mismas campañas que train, así que estima clientes nuevos de esa época, no una campaña futura. Eso es el hallazgo.

El encabezado cuenta la variante más larga.

A ACLARAR · PREGUNTAS PROBABLES

- **¿Por qué esperar para abrir el test?** Si una respuesta de la cátedra cambiara una variable o la métrica, habría que evaluar el test dos veces, y cada evaluación le quita independencia (N0-1). Pregunta 1.
- **El intervalo:** bootstrap estratificado sobre las predicciones de test, 2 000 remuestreos y percentiles del 95 %; no se reentrena nada (D-24).
- **¿Por qué no aparece «sin modelo»?** Porque el test no compite con nada: sólo mide. Es exactamente lo que la cátedra marcó en el TP1: comparar el número de test contra la línea de base parecía una decisión.
- **Cómo leer la diferencia con validación:** contra el desvío entre folds de validación, 0,006, y contra el intervalo de test. Dentro de $\pm 0,006$ es ruido, en cualquier sentido; si además da algo más bajo, es coherente con el optimismo de haber elegido los hiperparámetros en la misma validación que se reporta (slide 17), que no medimos (pregunta 11). Una diferencia mayor que un desvío ya no la explica el ruido; ese optimismo podría sumar algo, pero como no lo medimos no alcanza para descartar un problema: obliga a revisar la partición o el pipeline, y se dice (pregunta 30). En ningún caso se cambia el modelo después: lo que se promete es el número de test.
- **El test se evalúa una sola vez:** \nevaluaciones tiene que valer 1 en resultados-test.tex (gate G2).
- **El reentrenamiento con todo train** es el paso de la Clase 2, slides 88–89.

15 · El error caro es el «yes» que no se llama

6:20 → 6:45 · ~72 palabras · 2 [→] · página 34 del PDF

Habla: Sebastián

El error caro es el «yes» que no se llama

El problema · Datos · EDA · Métricas · Modelos · Hiperparámetros · **Modelo final** · Conclusiones · Hallazgo

validación (OOF): los 5 folds juntos
llamando al 20 % de la lista completa: 6 588 llamadas

	LLAMADO	NO LLAMADO
«yes»	2 329 «yes» alcanzados	1 382 «yes» perdidos
«no»	4 259 llamadas de más	24 970 bien descartados

- **1 382 «yes» sin llamar:** el error caro
- **2,8** llamadas por cada «yes» sin modelo: 8,9

MODELO FINAL

15/20

MIENTRAS EL TEST SIGA CERRADO, la matriz de la slide es la de validación, y se dice:

¿Qué errores comete? Con el test cerrado, la matriz es la de validación: los puntajes fuera de fold, llamando al 20 % de la lista. Un falso positivo es una llamada de más; un falso negativo, un cliente que habría contratado y no se llama: ese es el caro.

[→] Quedan 1 382 «yes» sin llamar, sobre todo de 2008 y sin historial.

[→] Aun así, cada «yes» cuesta 2,8 llamadas, contra 8,9 sin modelo.

Con el test evaluado, en la defensa, en lugar de lo anterior:

¿Qué errores comete? Es la matriz de test, llamando al 20 % de la lista. Un falso positivo es una llamada de más; un falso negativo, un cliente que habría contratado y no se llama: ese es el caro.

[→] Quedan ? «yes» de test sin llamar. En validación, los perdidos eran sobre todo de 2008 y sin historial.

[→] El recall de test, llamando al 20 %, es ?.

El encabezado cuenta la variante más larga.

A ACLARAR · PREGUNTAS PROBABLES

- **¿Qué es fuera de fold (OOF)?** Cada fila de train puntuada por el modelo del fold en el que no entrenó: toda train, sin fuga.
- **La matriz de validación completa:** 2 329 «yes» alcanzados, 1 382 perdidos, 4 259 llamadas de más y 24 970 bien descartados; 3 711 «yes» en total.
- **¿Por qué la lista completa y no fold por fold?** La matriz junta los puntajes fuera de fold de los 5 folds en una sola lista y la corta en su 20 %, 6 588 llamadas: es el corte de la curva de ganancia y el del test (1 647 llamadas). resultados/conclusiones.md, §3, usa el mismo corte y da las mismas cuatro celdas.
- **¿Quiénes son los perdidos?** En validación (conclusiones.md, §3): tres de cada cuatro son de 2008, un año en el que el modelo casi no llama, y casi todos no tienen campaña previa. En cambio, a los que tuvieron éxito en una campaña anterior los llama a todos.
- **El costo por «yes», en validación:** 2,8 llamadas es $(2\,329 + 4\,259) / 2\,329$; sin modelo, 8,9 es $1 / 0,113$, la inversa de la tasa de «yes».
- **Por qué el falso negativo es el caro:** una llamada de más cuesta una llamada; un cliente perdido es un plazo fijo que no se contrata. Es el costo desigual de la Clase 4, slides 41–44.

16 · ¿Por qué ganó Random Forest y quedó última la SVM?

6:45 → 7:25 · ~107 palabras · 3 [→] · página 38 del PDF

Habla: Sebastián

¿Por qué ganó Random Forest y quedó última la SVM?

El problema · Datos · EDA · Métricas · Modelos · Hiperparámetros · Modelo final · Conclusiones · Hallazgo

Random Forest · 0,795

no supone escala ni forma; es el que más pierde sin macro ni month: -0,059 (R4)

KNN · 0,784

mide distancias: sin escalar, pdays es el 86,6 % de la varianza

Naive Bayes · 0,782

supone independencia: tres macro con r de 0,91 a 0,97

SVM · 0,774

quedó lineal: el RBF no la mejora (0,772 en su mejor C)

AUC de validación · sin modelo: 0,500

CONCLUSIONES

16/20

Son los cuatro ejemplos del enunciado (TP2, p. 2): variables muy correlacionadas y distribuciones no gaussianas (Naive Bayes), diferencias de escala (KNN, SVM) y relaciones no lineales (RF, SVM). Como las fichas del deck, cada modelo lleva un supuesto y un efecto medido, y ninguna frase da una causa del orden como probada: la U de la edad se mezcla con la época, y no se midió qué pierde cada modelo sin la edad.

¿Por qué rindió cada uno? Por sus supuestos. Random Forest no supone escala ni forma, y es el que más pierde sin las variables de época: 0,059 en validación. Que gane por reconocer la época es inferencia.

[→] KNN mide distancias: sin escalar, en train, pdays tiene el 86,6 % de la varianza.

[→] Naive Bayes supone independencia, y en train el bloque macro la viola, con correlaciones de 0,91 a 0,97; como las numéricas no son normales, el categórico le gana al gaussiano.

[→] La SVM quedó lineal: el RBF no la mejora. Por qué queda última no lo medimos; entre los cuatro hay sólo 0,021 de AUC en validación.

A ACLARAR · PREGUNTAS PROBABLES

- **¿Qué pierde cada uno sin las variables de época?** En validación, con la configuración final (respaldo R4; D-25): Random Forest, 0,023 sin macro y 0,059 sin macro ni month; Naive Bayes, sin macro ni month, casi lo mismo: 0,058. Con la configuración de referencia de las ablaciones, sin macro ni month Random Forest pierde 0,093 (A8), también el que más. No medimos importancias de variables.
- **¿Por qué el bloque macro ayuda a Naive Bayes si viola la independencia?** Sacarlo cuesta 0,023 de AUC de validación en el gaussiano (A7; D-14), y 0,033 en el categórico. Es un resultado contra la intuición, probablemente porque fecha a los clientes (inferencia). Pregunta 15.
- **¿Entonces violar la independencia no tuvo ningún efecto?** Lo tuvo en las probabilidades, no en el orden (inferencia). Contar tres veces la época las lleva a los extremos —por eso Naive Bayes se puntúa con log-odds: la probabilidad llegaba a 1 exacto (src/metricas.py)—, pero el AUC sólo mide el orden, y ahí el bloque ayuda. Se ve en validación, fuera de fold: 3 121 filas, el 9,5 % de train, reciben $P(\text{yes}) \geq 0,99$, y de ellas contrata el 47,3 %; en el 10 % de la lista con mayor puntaje, la probabilidad media es 0,998 y la proporción de «yes», 0,464. Calibrar está entre las mejoras (conclusiones.md, §5).
- **¿Y la U de la edad?** No la damos como causa: se mezcla con la época (casi todos los mayores de sesenta son de 2009–2010; conclusiones.md, §1), y no se midió qué pierde cada modelo sin la edad.
- **¿La SVM con RBF no capta la U?** Podría, pero con y sin ajustar no la aprovechó (inferencia): con $C = 0,001$, en validación, el RBF da 0,768 y el lineal 0,774, y en su mejor C, 0,772. Un puntaje lineal en la edad, que entra en años (D-16), sube o baja, nunca las dos cosas; pero por qué la SVM queda última no lo medimos.
- **Las escalas, en train:** desvío de pdays 186,6 y de nr.employed 72,4; el mayor desvío de las numéricas es 374 veces el menor.
- **Las distribuciones no gaussianas, en train:** asimetría de campaign 4,89; pdays = 999 en el 96,3 %; la edad en U.

17 · Limitaciones: el test mide estas campañas, no una futura

7:25 → 8:00 · punto de control · ~100 palabras · 1 [→] · página 40 del PDF

Habla: Sebastián

Limitaciones: el test mide estas campañas, no una futura

El problema · Datos · EDA · Métricas · Modelos · Hiperparámetros · Modelo final · Conclusiones · Hallazgo

LIMITACIONES

La época: el test es de las mismas campañas

Llamar al 20 % es un supuesto de negocio

Hiperparámetros elegidos con la misma validación

QUÉ MEJORARÍAMOS

Validar hacia adelante en el tiempo

Más historial: el 86,3 % no tiene campaña previa

Un costo por tipo de error, no un 20 % fijo

CONCLUSIONES

17/20

Antes del hallazgo, siempre (guía A4, A7). Nunca se recorta.

Tres limitaciones, por impacto. La época: el test sale de las mismas campañas, así que vale para clientes nuevos de esas campañas, no para una futura. Llamar al 20 % es un supuesto: con el 10 % o el 30 %, Random Forest sigue primero en validación. Y elegimos los hiperparámetros con la misma validación que los reporta: el máximo sale algo optimista.

[→] Lo primero que haríamos es validar hacia adelante en el tiempo, que es como se usaría el modelo. Después, sumar historial: el 86,3 % de train no tiene campaña previa. Y un costo por tipo de error, en lugar del 20 %.

A ACLARAR · PREGUNTAS PROBABLES

- **¿Cuánto optimismo?** No lo medimos: haría falta una validación cruzada anidada (Clase 3, slides 98–100; D-22), y aquí ese papel lo cumple el test (pregunta 11). La regla de un error estándar lo atenúa, porque no elige el máximo: profundidad 8 y no 10 (conclusiones.md, §4).
- **¿Y dentro de una campaña?** El 0,795 y el 0,629 de validación ordenan una lista que mezcla 2008–2010. Fuera de fold, en los pares del mismo año el AUC es 0,658, y en los del mismo año y mes, 0,564; llamando al 20 % de cada año por separado, el recall es 0,378 (pregunta 27).
- **La sensibilidad al presupuesto**, en validación: Random Forest alcanza 0,446, 0,629 y 0,705 de los «yes» llamando al 10 %, 20 % y 30 %, contra 0,100, 0,200 y 0,300 sin modelo; su precisión baja de 0,502 a 0,265 (respaldo R2).
- **¿Y el desbalance?** Pesos balanceados en Random Forest: +0,0006 de AUC de validación, positiva en los 5 folds pero despreciable por su tamaño (N0-12).
- **¿Y unknown?** Imputar es neutro: Random Forest +0,0011 de AUC de validación (D-08).
- **¿Y campaign?** Puede depender del resultado (D-07); el efecto no se midió.
- **¿Y duration?** Con ella, Random Forest llega a 0,939 de AUC de validación, pero no existe antes de llamar (slide 4).
- **Otra mejora:** calibrar las probabilidades, porque un costo por tipo de error necesita probabilidades y hoy sólo cuenta el orden (inferencia; conclusiones.md, §5).


18 · Entrenado con el pasado, Random Forest cae de 0,795 a 0,558

8:00 → 8:30 · ~77 palabras · 1 [→] · página 42 del PDF

Habla: Andrés

Entrenado con el pasado, Random Forest cae de 0,795 a 0,558

El problema · Datos · EDA · Métricas · Modelos · Hiperparámetros · Modelo final · Conclusiones · Hallazgo



Barajado, AUC 0,864 en pares «yes»–«no» de años distintos y 0,658 en los del mismo año

HALLAZGO

18/20

(bloque 5, slides 18–20). Entra enganchado con la última frase de Sebastián: validar hacia adelante.

El hallazgo. Validamos hacia adelante dentro de train: cada fold entrena con el pasado y valida con el bloque siguiente. Barajados, los cuatro están entre 0,774 y 0,795; hacia adelante, ninguno pasa de 0,598, y Random Forest cae a 0,558.

[→] ¿Por qué tanto? Parte del 0,795 es distinguir años: en los puntajes fuera de fold, el 66,3 % de los pares «yes»–«no» son de años distintos, y ahí el AUC es 0,864; en los del mismo año, 0,658.

A ACLARAR · PREGUNTAS PROBABLES

- **¿Cómo se validó hacia adelante?** TimeSeriesSplit con 5 folds sobre train ordenado por fecha: cada fold valida con un bloque de 5 490 filas y entrena con todo lo anterior, de 5 490 a 27 450 filas (D-25). Todo dentro de train: el test no participa.
- **¿Por qué el desvío hacia adelante es tan grande ($\pm 0,123$ en Random Forest)?** Porque el modelo sirve en dos bloques y en tres no: los tres de 2008 entrenan con pocos «yes», de 159 a 778, y dan de 0,426 a 0,500; los de 2009–2010 entrenan con 1 084 y 1 780, y dan 0,664 y 0,711. No es la tasa de «yes» de cada bloque, que va de 4,7 % a 35,2 %: el AUC no depende de ella, porque la ROC calcula cada tasa dentro de su clase (Clase 4, slides 45–51). Y no es sólo entrenar con pocos «yes»: 2008 cuesta ordenarlo aun entrenando con todas las épocas; barajado, en las mismas filas, da de 0,519 a 0,584, contra 0,748 y 0,762 en 2009–2010.
- **¿Y para elegir a quién llamar dentro de una campaña?** Pregunta 27.
- **Los cuatro, hacia adelante:** Random Forest 0,558, KNN 0,539, Naive Bayes 0,598 y SVM 0,541; barajados, en validación, 0,795, 0,784, 0,782 y 0,774. Random Forest pierde 0,237. En recall al 20 %, hacia adelante da 0,243.
- **La cuenta de los pares:** el AUC es la proporción de pares «yes»–«no» bien ordenados; el de los pares del mismo año es el de cada año ponderado por sus pares, y el de años distintos sale por diferencia (conclusiones.md, «Cómo se calculó»). Por año, fuera de fold: 2008, 0,598; 2009, 0,759; 2010, 0,749.
- **Por qué los pares entre años son fáciles:** en train, 2008 tiene 4,9 % de «yes» y 2010, 51,9 %; basta con reconocer la época para ordenarlos bien (inferencia).


19 · En 2008 no sirve; en 2009–2010 pierde, pero no cae al azar

8:30 → 8:55 · ~71 palabras · 1 [→] · página 44 del PDF

Habla: Andrés

En 2008 no sirve; en 2009–2010 pierde, pero no cae al azar

El problema · Datos · EDA · Métricas · Modelos · Hiperparámetros · Modelo final · Conclusiones · Hallazgo



HALLAZGO

19/20

Es lo último que se muestra (guía A6). Si el reloj va atrasado, el segundo paso se reduce a la frase de recorte del «Reloj de ensayo».

Bloque a bloque: en los tres bloques de 2008, hacia adelante no pasa de 0,5, y en el tercero, 0,426, el orden incluso se invierte.

[→] Pero barajado, en esas mismas filas, tampoco pasa de 0,584: en 2008 el modelo no sirve ni mezclando épocas. En los dos bloques de 2009–2010, en cambio, pierde 0,084 y 0,051: una caída real, pero no al azar. Por eso el test vale para estas campañas.

A ACLARAR · PREGUNTAS PROBABLES

- **¿Es por que las variables macro fechan las filas?** No: hacia adelante, sin ellas da 0,556, y sin ellas ni month, 0,547 (respaldo R4). Barajado, en validación, esas mismas variantes quedan en 0,772 y 0,736, es decir, pierden 0,023 y 0,059. No es sólo que fechen a los clientes: la relación entre las variables y el «yes» cambia con el tiempo (inferencia).
- **¿Por qué no validar así desde el principio?** El enunciado plantea k-fold; un esquema temporal habría entrenado con 2008, con 4,9 % de «yes» en train, para predecir 2010, con 51,9 % (D-25). Es la primera mejora.
- **Hacia adelante, bloque a bloque** (anotado en la figura): 0,489, 0,500, 0,426, 0,664 y 0,711.
- **¿0,426 es azar?** No: es peor que el azar. Un AUC por debajo de 0,5 ordena al revés, el «mal» clasificador de la Clase 4 (slides 45–51). Es la señal más fuerte de que la relación entre las variables y el «yes» cambia con el tiempo (inferencia). No le calculamos un intervalo, así que no decimos a cuántos errores estándar queda de 0,5.
- **Barajado en las mismas filas** (el AUC fuera de fold de Random Forest en las filas de cada bloque): 0,536, 0,519, 0,584, 0,748 y 0,762. Hacia adelante pierde 0,047, 0,019, 0,158, 0,084 y 0,051.
- **Los bloques:** mayo–julio, julio–agosto y agosto–noviembre de 2008; noviembre de 2008 a mayo de 2009; mayo de 2009 a noviembre de 2010. El «yes» de cada uno: 4,7 %, 6,5 %, 5,6 %, 12,7 % y 35,2 %. Los «yes» con que entrena cada fold: 159, 419, 778, 1084 y 1780; el primero, con apenas 159, es el de 0,489.
- **Qué significa para el banco:** el número de test valdrá para clientes nuevos de estas campañas. Para una campaña futura, la mejor referencia que tenemos es la validación hacia adelante de 2009–2010, 0,664 y 0,711 (inferencia).

GRACIAS

¿Preguntas?

Grupo 7 — Andrés Cortese (64612) · Sebastián Caules (64331)
Instituto Tecnológico de Buenos Aires — 72.75 Aprendizaje Automático

Trabajo Práctico 2: clasificación supervisada — Defensa: 07/10/2026

PREGUNTAS

20/20

Gracias; quedamos a disposición para las preguntas.

A ACLARAR · PREGUNTAS PROBABLES


- **Esta slide queda puesta durante las preguntas.** Después vienen las cuatro de respaldo, fuera del recorrido: R1, la curva de ganancia; R2, la sensibilidad al presupuesto; R3, las ablaciones del análisis exploratorio; R4, el hallazgo sin las variables de época.
- **Los respaldos, por si hay que buscar un número:** informe/numeros.md (cada cifra con su fuente), resultados/conclusiones.md, DECISIONES.md y los CSV de resultados/.

Respaldo

Las 4 slides de respaldo van después de la 20, fuera del recorrido (páginas 46 a 49 del PDF), y se muestran sólo si una pregunta las pide.

Con el 20 % de la lista, Random Forest alcanza el 62,8 % de los «yes»

El problema · Datos · EDA · Métricas · Modelos · Hiperparámetros · Modelo final · Conclusiones · Hallazgo




RESPALDO

R1/4

R1 · página 46 del PDF

Con el 10 % o el 30 % de la lista, Random Forest sigue primero

El problema · Datos · EDA · Métricas · Modelos · Hiperparámetros · Modelo final · Conclusiones · Hallazgo



RESPALDO

R2/4

R2 · página 47 del PDF · pregunta 9

De las ablaciones se adoptan dos, y dos alimentan el hallazgo

El problema · Datos · EDA · Métricas · Modelos · Hiperparámetros · Modelo final · Conclusiones · Hallazgo

■ mejora ($\Delta > \text{desvío}$) ■ empeora ($\Delta < -\text{desvío}$) ■ neutra — no se mide

	NB gaussiano	SVM	KNN	RF
A2 sin pdays	-0,0012	+0,0023	-0,0019	+0,0003
A3 default como indicadora · adoptada	-0,0003	+0,0004	+0,0000	+0,0029
A4 funde categorías raras · adoptada	+0,0008	+0,0002	+0,0001	-0,0000
A5 log1p(campaign)	—	-0,0006	+0,0008	—
A6 bloque macro reducido	-0,0041	+0,0030	-0,0083	+0,0005
A7 sin bloque macro	-0,023	-0,0037	-0,048	-0,028
A8 sin bloque macro ni month	-0,050	-0,048	-0,076	-0,093
A9 sin day_of_week	-0,0000	-0,0074	-0,0014	-0,0034
A10 edad en tramos	+0,0001	—	—	—
A11 unknown → moda	+0,0000	-0,0002	+0,0001	+0,0011
A12 sin escalar	—	—	+0,0084	—

Δ AUC de validación contra A0
sin modelo: AUC de validación 0,500


RESPALDO

R3/4

R3 · página 48 del PDF

Sin las variables de época, hacia adelante no mejora

El problema · Datos · EDA · Métricas · Modelos · Hiperparámetros · Modelo final · Conclusiones · Hallazgo



RESPALDO

R4/4

R4 · página 49 del PDF · pregunta 28

Los 10 minutos de preguntas

Respuestas cortas, con el dato al frente y su conjunto declarado. Entre corchetes, a qué slide conviene volver y quién responde primero: el que presentó ese bloque. Las citas de clase son sólo las que ya están en DECISIONES.md o en plan/PLAN.md (ver «Convenciones»).

Para volver a una slide. El pie dice «n/20» y la página del PDF no coincide, por los overlays. Página de la última variante de cada slide: 1 → 1 · 2 → 4 · 3 → 8 · 4 → 10 · 5 → 12 · 6 → 14 · 7 → 19 · 8 → 22 · 9 → 23 · 10 → 26 · 11 → 27 · 12 → 29 · 13 → 30 · 14 → 31 · 15 → 34 · 16 → 38 · 17 → 40 · 18 → 42 · 19 → 44 · 20 → 45 · R1 → 46 · R2 → 47 · R3 → 48 · R4 → 49.

EL TEST Y LOS DATOS

1. ¿Por qué no evaluaron el test todavía?

[slide 14 · Sebastián]

Porque las consultas a la cátedra podían cambiar una variable, la métrica o la partición, y evaluar antes de saberlo obligaba a evaluar dos veces: cada evaluación le quita independencia al test (N0-1). En el TP1 se evaluó más de una vez sobre la misma partición y quedó como limitación; aquí no se repite. El módulo está construido y probado sin abrir el test, corre una sola vez después del 30/09 y registra cuántas veces corrió. *Si en la defensa siguiera cerrado:* la única estimación disponible es la de validación, 0,795, y sale algo optimista; cuánto, no lo medimos (pregunta 11).

2. ¿Cómo garantizan que ninguna decisión miró el test?

[slide 3 · Andrés]

Todo lo anterior al punto 4 lee sólo train con `cargar_train()`. El único módulo que evalúa un modelo en test es `src/evaluar_test.py`. Otros cuatro archivos pueden nombrar el test o el CSV completo, y ninguno elige nada del modelo: `src/datos.py`, que hace la partición; `tests/test_datos.py`, que verifica que train y test sean disjuntos y reconstruyan el dataset; `src/evidencia_particion.py`, que mide la partición misma sobre el archivo completo (D-02, D-03); y el propio `tests/test_aislamiento.py`, que nombra lo que busca. Fuera de esa lista blanca de cinco archivos, `tests/test_aislamiento.py` falla si cualquier `.py` nombra el test o el CSV completo (D-04). El análisis exploratorio que decide corre sobre train: una primera versión corrió sobre el CSV completo y se rehízo sobre train antes de decidir nada (D-04). Además, todo lo que se aprende de los datos —escalado, deciles, codificación— vive dentro del Pipeline y se ajusta en cada fold (`tests/test_preproceso.py`).

3. ¿Por qué partición aleatoria, si el archivo está ordenado por fecha?

[slides 5 y 19 · Sebastián]

El enunciado plantea k-fold y no menciona el tiempo, y con el último 20 % del archivo como test se entrenaría en una época y se evaluaría en otra: train tendría 6,4 % de «yes» y test 30,8 % (D-03). Lo que cuesta no está escondido: está medido en las slides 18 y 19, y por eso la slide 14 dice «de la misma época». Es la consulta 5 a la cátedra.

4. ¿Por qué estratificaron, si no se vio en clase?

[slide 3 · Andrés]

Porque sin estratificar la proporción de «yes» del test cambia con la semilla: en 400 particiones, con un desvío de 0,31 puntos, entre 10,4 % y 12,1 %. El efecto es pequeño, pero estratificar no cuesta nada: train y test quedan con el mismo 11,3 % (D-02).

5. ¿Por qué duration fuera, si es la mejor variable?

[slide 4 · Sebastián]

Porque se conoce al colgar, cuando y ya se sabe, y el propio diccionario pide descartarla para un modelo realista (`bank-additional-names.txt`, atributo 11; D-05). Con ella Random Forest llega a 0,939 de AUC de validación, pero ese número no existe antes de llamar, que es cuando opera el modelo (TP2, p. 1).

6. ¿Hay otras variables con fuga?

[slide 2 · Andrés]

La que tiene reserva es `campaign`: cuenta la llamada que se va a hacer, pero cada fila guarda el total al cierre de la campaña, y tras un «yes» no se vuelve a llamar (inferencia). En train, la media es 2,053 en los «yes» y 2,627 en los «no», con la misma mediana, 2: compatible, no concluyente; el efecto no se midió (D-07). `month`, `day_of_week` y `contact` son de la llamada que se va a hacer (inferencia): es la consulta 2. Y los indicadores trimestrales, `emp.var.rate` y `nr.employed`: `bank-additional-names.txt` no dice con qué rezago se asignó el valor a cada fila, y suponemos el último publicado al llamar (inferencia; D-07). Que delaten la época es un problema de robustez temporal, no de fuga (D-25).

7. ¿El mismo cliente puede estar en train y en test?

[slide 3 · Andrés]

No se puede descartar. El dataset no trae identificador de cliente (`bank-additional-names.txt` omite atributos por privacidad), así que no se puede partir por cliente, y D-01 sólo quita los duplicados exactos. Sin `duration`, en train se repiten 1 153 combinaciones de las 19 predictoras, en 2 482 filas, el 7,5 % de train; 156 de ellas aparecen con «yes» y con «no», en 350 filas. Con `duration` no se repite ninguna, así que son llamadas distintas: clientes distintos con los mismos datos o el mismo cliente dos veces, y sin identificador no se sabe. Si un cliente cae en train y en test, el test sale algo optimista; no lo podemos medir, y es una limitación más. Esas repeticiones explican también el 0,988 de KNN con un vecino en train (slide 11).

DECISIONES DISCUTIBLES

8. KNN sin escalar da más. ¿Por qué no lo usaron?

[slide 7 · Sebastián]

Da +0,0084 de AUC de validación con desvío 0,0067, y pasaba nuestra regla de adopción: lo rechazamos por juicio, y está declarado (D-12). Mejora por la razón equivocada: sin escalar, `pdays` y `nr.employed` son el 86,6 % y el 13,0 % de la varianza de las numéricas de `train`, así que la distancia mide historial de contacto y época —`nr.employed` es un reloj—. Es evidencia del hallazgo, no una mejora del modelo; y la teoría pide escalar a los métodos de distancia (Clase 8, slide 54; Alpaydın §8.3, p. 192).

9. ¿De dónde sale el 20 %?

[slide 8, respaldo R2 · Andrés]

Es un supuesto de negocio, declarado (D-20). Lo que no depende del supuesto es el orden: en validación, llamando al 10 % o al 30 %, Random Forest sigue primero, con recall 0,446 y 0,705 contra 0,100 y 0,300 sin modelo; los otros tres cambian de orden entre sí. No usamos el umbral de la Clase 4, el punto de la ROC más cercano a (0,1) (slide 52), porque es simétrico entre los dos errores y aquí no cuestan lo mismo (slides 41–44); y con un umbral por modelo los recalls no se comparan.

10. ¿Por qué no trataron el desbalance, por ejemplo remuestreando?

[slides 8 y 12 · Andrés]

No remuestreamos: las dos métricas ya no premian decir siempre «no» (D-19, D-21), y remuestrear sería agregar un método que no se dio en clase (consulta 3). Pero el desbalance no sólo mueve el umbral: puede sesgar el ajuste, y por eso los pesos de clase se midieron como hiperparámetro (D-21). En la SVM, `C` es el costo de violar el margen (Clase 8, slide 49), y con 7,9 «no» por cada «yes» ese costo lo dominan los «no»; `balanced` multiplica `C` por el peso de cada clase, así que cada «yes» pesa 7,9 veces más. Si los pesos sólo movieran el umbral, el AUC no cambiaría; en validación, con RBF y `C = 1`, sube $0,068 \pm 0,011$ fold a fold, y sube en los 5 folds; en el mejor `C` de cada una, de 0,706 sin pesos a 0,772 con pesos: cambian el orden, y se adoptan. En Random Forest sube sólo 0,0006, también en los 5 folds, pero es despreciable por su tamaño (N0-12): en cada hoja, el peso reescala la proporción de «yes», casi como mover el umbral (inferencia).

11. ¿No sobreajustaron la validación con tantas decisiones?

[slide 17 · Sebastián]

Algo, y está declarado como limitación: es el sobreajuste a la validación de la Clase 3, slides 98–100. Elegir el mejor entre muchas estimaciones con ruido también elige ruido favorable, y las ablaciones, las curvas y los modelos de referencia usaron los mismos 5 folds: el 0,795 sale optimista, y no medimos cuánto. De las cuatro defensas del slide 100 usamos tres: validación cruzada (D-06); búsquedas acotadas, porque las ablaciones y las grillas estaban en el plan —lo agregado después, como la extensión de KNN hasta 801 y las curvas de `C` con pesos, queda registrado en `hiperparametros.json`— y la regla de un error estándar no elige el máximo (D-22); y un test intacto que se abre una vez (D-04). La cuarta, la validación cruzada anidada, no la corrimos (D-22): el test intacto ya cumple el papel de la evaluación externa, y con cinco folds externos multiplicaría por cinco los ajustes de cada curva. Lo que se promete es el número de test.

12. ¿Por qué 200 árboles, si la regla de un error estándar daba 25?

[slide 10 · Andrés]

Porque el número de árboles no es un eje de complejidad sino de estabilidad: más árboles no cambian el sesgo y sólo bajan la varianza (Clase 7, slide 61), así que «el más simple» no aplica. Con profundidad 8 la curva es plana en validación: 25 árboles dan 0,793 y 800 dan 0,796; 200 está en la meseta, con 0,795, y da puntajes menos gruesos para ordenar la lista. Es un desvío de la regla, y está declarado (N0-11).

13. ¿Por qué Random Forest sin pesos de clase, si la regla elegía `balanced`?

[slide 10 · Andrés]

Porque la mejora es despreciable por su tamaño: +0,0006 de AUC de validación, y fold a fold, la diferencia es $+0,0006 \pm 0,0009$, positiva en los 5 folds. Se descarta por el tamaño, no por ruido: D-21 adopta los pesos sólo si la mejora vale la pena, y sin pesos el modelo es el de la Clase 7 tal cual (N0-12). La regla de D-22 daba `balanced` porque para los pesos no hay un orden de simplicidad, y toma el mayor AUC. En la SVM, en cambio, suben $0,068 \pm 0,011$, también en los 5 folds, y se adoptan (D-21).

14. ¿Por qué no validaron hacia adelante como esquema principal?

[slide 19 · Andrés]

Porque el enunciado plantea k-fold, y un esquema temporal habría entrenado con 2008, con 4,9 % de «yes» en `train`, para predecir 2010, con 51,9 % (D-25). Lo medimos dentro de `train` como limitación y es la primera mejora: es como se usaría el modelo. Si la cátedra responde otra cosa en la consulta 5, el código ya lo tiene (`src/robustez.py`).

LA TEORÍA DE LOS CUATRO MODELOS

15. ¿Qué supone Naive Bayes y cómo lo afectan estos datos?

[slides 9 y 16 · Sebastián]

Independencia de las variables dada la clase. El bloque macro la viola: en train, tres de sus cinco variables tienen correlaciones de 0,91 a 0,97, y aun así sacarlo le cuesta 0,023 de AUC de validación al gaussiano (D-14), probablemente porque fecha a los clientes (inferencia). El gaussiano supone además una normal por clase, y en train pdays es casi binaria, campaign tiene asimetría 4,89 y la edad forma una U. Por eso el del TP es el categórico: deciles aprendidos en cada fold y Laplace con $\alpha = 1$ (Clase 6, slide 46). Le gana al gaussiano por 0,013 de AUC de validación, y en los cinco folds (D-18). Si repreguntan dónde se nota la violación: aclaraciones de la slide 16.

16. ¿Para qué la corrección de Laplace? ¿Dónde les aparecía un cero?

[slides 7 y 9 · Sebastián]

Un valor que en el fold de entrenamiento nunca aparece con «yes» tendría probabilidad 0 y anularía el producto de Naive Bayes. Laplace suma $\alpha = 1$ a cada conteo: $(\text{conteo} + 1) / (N + k)$, con k los valores posibles del atributo (Clase 6, slide 46). En los cinco folds barajados ningún valor presente en el entrenamiento tiene conteo cero en una clase: el único caso, `default = yes`, 2 filas de train y las dos «no», lo quitó D-09. Ahí $\alpha = 1$ sólo suaviza, y no se ajustó porque el punto 3.1 no lo pide para Naive Bayes (D-22). Hacia adelante sí importa: el bloque siguiente trae valores nunca vistos, como meses nuevos, con conteo cero en las dos clases. Sin α , el log-odds quedaría indefinido; con $\alpha = 1$, cada uno empuja hacia el «yes», porque la clase con menos filas tiene el denominador menor (inferencia).

17. ¿Qué hace C en la SVM, y por qué quedó en 0,001?

[slide 12 · Andrés]

C es el costo de las violaciones del margen: con la convención de scikit-learn, un C grande castiga más y regulariza menos (Clase 8, slide 49). Con kernel lineal la curva es plana en validación, 0,001 y 0,01 empatan en 0,774, y la regla toma el más regularizado. Con RBF, un C grande lleva train casi a uno y la validación cae: sobreajuste.

18. ¿Por qué lineal y no RBF? ¿Y y?

[slide 12 · Andrés]

Comparados con $C = 0,001$ en validación: lineal 0,774, polinómico 0,774 y RBF 0,768; el RBF en su mejor C, 0,01, llega a 0,772. y no se ajustó: la grilla conjunta de C y γ (Clase 8, slides 48–49) quedó como opcional una vez que el kernel final fue lineal. La lineal va con LinearSVC porque la de libsvm con $C = 10$ no terminó en 600 segundos (D-22): es la misma SVM lineal de margen blando, resuelta con liblinear, y lo único que cambia es que liblinear también regulariza el término independiente.

19. ¿Por qué hay que escalar para KNN y la SVM, y no para Random Forest?

[slides 7 y 16 · Sebastián]

KNN y la SVM miden distancias, y sin escalar las decide la variable de mayor varianza (Clase 8, slide 54; Alpaydin §8.3, p. 192): en train, pdays tiene desvío 186,6 y nr.employed 72,4. Un árbol corta cada variable por separado, así que la escala no le cambia nada (D-12).

20. ¿No es enorme $k = 801$? ¿Y la ponderación por distancia?

[slide 11 · Andrés]

En KNN sobreajusta el k pequeño: con un vecino, train 0,988 y validación 0,619. Desde 151 todo queda dentro de un error estándar del mejor, y se toma el más suave: 801, con 0,784 de validación y brecha 0,006. Con 26 352 filas por fold y 11,3 % de «yes» en train, estimar bien una proporción baja pide muchos vecinos (inferencia). Por distancia (Mitchell §8.2.1), cada punto de train se encuentra a sí mismo: train 1,000 y validación 0,770 con $k = 801$, el que elige la misma regla; con más de un vecino queda por debajo de la uniforme en todo el rango.

21. ¿ $k = 801$ y $C = 0,001$ no quedaron en el borde de sus grillas?

[slides 11 y 12 · Andrés]

Sí, los dos, y no por la misma razón. En KNN, el máximo quedó primero en el borde de una grilla más corta, así que la extendimos hasta 801: es la extensión que declara la pregunta 11. Con ella, el máximo, 601, quedó adentro, y la curva de validación es una meseta desde 301, entre 0,783 y 0,784. 801 está en el borde porque la regla elige el más suave de los que empatan, y la meseta llega hasta el final de la grilla: un k mayor probablemente también empataría, sin cambiar el AUC (inferencia). En la SVM, 0,001 es el menor C de la grilla: con kernel lineal, 0,001 y 0,01 empatan en 0,774 de validación, y la regla toma el más regularizado. Un C menor sería una SVM lineal aún más regularizada, y no la probamos: no sabemos si seguiría empatando o empezaría a subajustar.

22. ¿Por qué Random Forest no sobreajusta con más árboles, pero sí con más profundidad?

[slide 10 · Andrés]

La profundidad es la complejidad de cada árbol: sin límite, train llega a 1,000 y validación baja a 0,772, brecha 0,228. Los árboles, en cambio, se promedian: bajan la varianza sin cambiar el sesgo (Clase 7, slide 61). El protocolo de las curvas —train y validación con los mismos folds, la brecha como lectura del sobreajuste— es el de la Clase 7, slide 50.

23. ¿Qué significa un AUC de 0,795?

[slide 8 · Andrés]

La probabilidad de que, tomando al azar un «yes» y un «no» de validación, el modelo le dé más puntaje al «yes». Sin modelo es 0,5. No depende del umbral y no premia decir siempre «no» (Clase 4, slides 45–51). Llamando al 20 % de la lista, eso se traduce en 0,629 de recall de validación. Esa lista mezcla 2008–2010, y ordenar dentro de un mismo año es más difícil (pregunta 27).

24. ¿Los modelos son realmente distinguibles?

[slide 13 · Sebastián]

Random Forest supera a KNN por 0,011 de AUC de validación, con un error estándar de 0,0025: el umbral de empate es 0,7927 y no entra ninguno (D-23). Pero conviene decir la escala: entre los cuatro hay 0,021, y entre Random Forest y sin modelo, 0,295. Y el error estándar supone folds independientes, cuando sus train se superponen en tres cuartos: el real es algo mayor (inferencia).

25. ¿Por qué 5 folds?

[slide 3 · Andrés]

Es el esquema del TP1 (D-06): cada vuelta entrena con 26 352 filas de train y valida con 6 588, y el desvío entre folds del AUC de validación de Random Forest es 0,006, así que la estimación ya es estable. No comparamos otros k. Lo que sí importa es que los folds estén barajados: sin barajar, cada uno quedaba en una época (slide 5).

EL HALLAZGO

26. ¿El hallazgo no invalida el modelo?

[slides 18–19 · Andrés]

No invalida el número de test: dice qué mide. El test es una muestra al azar de las mismas campañas, así que vale para clientes nuevos de esas campañas, ordenados en una lista que las mezcla (pregunta 27). Hacia adelante, en los dos bloques de 2009–2010, Random Forest conserva 0,664 y 0,711: pierde, pero no cae al azar. En 2008 no servía ni barajado: 0,598 fuera de fold.

27. Si el banco elige a quién llamar dentro de una campaña, ¿cuánto valen el AUC y el recall?

[slide 18 · Andrés]

Menos. El 0,795 y el 0,629 de validación ordenan una lista que mezcla 2008–2010, y parte de su valor es reconocer la época. Fuera de fold, en los pares «yes»–«no» del mismo año el AUC es 0,658 (D-25, lectura (a)), y por año, 0,598, 0,759 y 0,749; en los del mismo año y mes, más cerca de una campaña, 0,564. Con el recall pasa lo mismo: llamando al 20 % de cada año por separado, Random Forest alcanza el 0,378 de los «yes», con 4,7 llamadas por «yes» (2,8 con la lista mezclada); al 20 % de cada año y mes, el 0,295. La vara de esos recalls es el 0,200 del azar, que repartir las llamadas no cambia, no el 0,629. El recall de cada año es 0,306, 0,455 y 0,311, y en 2010 no puede pasar de 0,385: hay 864 «yes» y sólo 333 llamadas. El test es la misma mezcla (D-03): tendrá el mismo sesgo.

28. ¿No es sólo que las variables económicas delatan la fecha?

[respaldo R4 · Andrés]

No: hacia adelante, sin el bloque macro Random Forest da 0,556, y sin el bloque macro ni month, 0,547, casi lo mismo que con todas, 0,558. Barajado, en validación, sacarlas sí cuesta: quedan en 0,772 y 0,736, es decir, pierden 0,023 y 0,059. La relación entre las variables y el «yes» cambia con el tiempo (inferencia).

29. ¿Qué harían distinto con más tiempo?

[slide 17 · Sebastián]

Por impacto: validar hacia adelante como esquema principal, que mide una campaña futura; más historial del cliente, porque el 86,3 % de train no tiene campaña previa; un costo por tipo de error en lugar del 20 % fijo (Clase 4, slides 41–44); y calibrar las probabilidades para poder usar ese costo (inferencia).

30. ¿Y si el test da bastante distinto que validación?

[slide 14 · Sebastián]

Depende de cuánto. Se lee contra el desvío entre folds de validación, 0,006, y contra el intervalo del 95 % del test. Una diferencia dentro de $\pm 0,006$ es ruido, en cualquier sentido: es lo que ya varía el AUC de un fold a otro. Si da algo más bajo, puede sumarse el optimismo que declaramos en la slide 17, que no medimos (pregunta 11), y por eso no sirve para descartar nada: una diferencia mayor que un desvío obliga a revisar la partición o el pipeline, buscando qué separa al test de train, y se dice tal cual. En ningún caso se cambia el modelo después de abrirlo: lo que se promete es el número de test. Y en ningún caso se lo compara con «sin modelo».

LAS CONSULTAS A LA CÁTEDRA

31. ¿Qué le consultaron a la cátedra, y qué pasa si responde distinto?

[— · los dos]

Seis consultas, cada una con un valor por defecto para no bloquear el trabajo (`plan/consultas.md`): si F_1 cuenta entre las métricas vistas; si con `duration` alcanza con excluirla, y si `month`, `day_of_week`, `contact` y `campaign` se consideran disponibles antes de llamar; si esperan que se trate el desbalance; qué Naive Bayes esperan con datos mixtos; si la partición debe ser aleatoria o temporal; y qué día defendemos. Desde el principio se guardaron las cinco métricas candidatas y las dos variantes de Naive Bayes, así que una respuesta distinta cambia qué columna se lee, no qué se vuelve a correr. Las que más moverían el trabajo son la de las variables del último contacto —la variante sin ellas está anotada como pendiente— y la de la partición. **Antes de la defensa, actualizar esta respuesta con lo que la cátedra haya contestado.**