

Slides y guion

Defensa del TP2 — Grupo 7

¿Quién va a contratar un plazo fijo? — Trabajo Práctico 2: clasificación supervisada

72.75 Aprendizaje Automático — ITBA — 2026 Q2

Andrés Cortese (64612) · Sebastián Caules (64331)

Defensa: **07/10/2026 (o 14/10)** · 10 + 10 minutos

RELOJ TOTAL

8:30

1 364 palabras a 2,7 por segundo dan 8:25; las ventanas del guion terminan en 8:30. El tope hablado es 9:45. 20 slides en el guion, con 25 **[→]**; el PDF de proyección tiene 45 páginas en la charla.

QUIÉN HABLA

Andrés	690 palabras	4:16	slides 1-3, 8-12 y 18-20
Sebastián	674 palabras	4:10	slides 4-7 y 13-17

CÓMO LEERLO

Cada página es una slide del deck en su **estado final**, con todos los overlays revelados, junto a su texto hablado. Arriba van la ventana de reloj, las palabras, las pulsaciones y la página del PDF, para volver a ella en las preguntas.

Lo que va en letra normal se dice, y la marca **[→]** indica dónde se avanza un overlay. Lo que va en gris cursiva son indicaciones de ensayo, y el bloque «A aclarar» es material para las preguntas: nada de eso se dice en voz alta.

El test todavía no se evaluó (informe/resultados-test.tex): en las slides 14 y 15 va primero la variante con el test cerrado, que es la que muestra la imagen, y debajo, en gris, la de la defensa.

Reloj de ensayo

Slide	Título corto	Empieza	Dura	[→]	Bloque	Quién
1	Portada	0:00	0:05	0	marco	Andrés
2	El problema	0:05	0:30	2	marco	Andrés
3	Qué datos deciden	0:35	0:30	3	teoría	Andrés
4	duration, fuera	1:05	0:20	1	EDA	Sebastián
5	El archivo va por fecha	1:25	0:30	1	EDA	Sebastián
6	El 999 de pdays	1:55	0:15	1	EDA	Sebastián
7	El pipeline y el IQR	2:10	0:35	4	EDA	Sebastián
8	Dos métricas	2:45	0:35	2	teoría	Andrés
9	Modelos sin ajustar	3:20	0:25	0	resultados	Andrés
10	Curva de Random Forest	3:45	0:35	2	resultados	Andrés
11	Curva de KNN	4:20	0:25	0	resultados	Andrés
12	Curva de la SVM	4:45	0:20	1	resultados	Andrés
13	Modelo final	5:05	0:20	0	resultados	Sebastián
14	El test	5:25	0:30	0	resultados	Sebastián
15	Los errores	5:55	0:25	2	resultados	Sebastián
16	Por qué rindió cada uno	6:20	0:40	3	resultados	Sebastián
17	Limitaciones y mejoras	7:00	0:30	1	resultados	Sebastián
18	Hallazgo: la caída	7:30	0:25	1	hallazgo	Andrés
19	Hallazgo: bloque a bloque	7:55	0:30	1	hallazgo	Andrés
20	¿Preguntas?	8:25	0:05	0	marco	Andrés

Puntos de control al ensayar.

- Al terminar la **slide 3** tienen que haber pasado **1:05**: la regla de juego está dicha y todavía no se mostró ningún resultado.
- Al terminar la **slide 7** tienen que haber pasado **2:45**. Es el control más importante: el EDA está cerrado con sus cuatro consecuencias, y todo lo anterior es marco, teoría y datos. Si pasaron más de 3:00, se aplican ya los recortes 3 y 4, que caen en las slides 9 y 11, y se da por hecho el recorte 1. Nunca se recorta en la 10.
- Al terminar la **slide 13** tienen que haber pasado **5:25**: el modelo está elegido y lo que queda del punto 4 es el test. Si pasaron más de 5:40, se aplica el recorte 1; si más de 5:55, también el 2.
- Al terminar la **slide 17** tienen que haber pasado **7:30**: todo lo calificable está dicho (gate G5). Lo que queda es el hallazgo, que es lo mejor del trabajo pero no un punto de la consigna. Si pasaron más de 7:45, el hallazgo va con los recortes 1 y 2.

Orden de recorte, si hay que recortar en vivo. Es un orden de prioridad: lo primero que se sacrifica es lo último que se dice.

- Primero, el segundo paso del hallazgo.** En la slide 19, el segundo overlay se reduce a una frase: «Barajado, en esas filas tampoco pasa de 0,584; en 2009–2010 pierde, pero no cae al azar. Por eso el test vale para estas campañas.» De 46 a 24 palabras: unos 8 segundos.
- Después, el segundo overlay de la 18:** «Parte del 0,795 es distinguir años: entre años distintos el AUC es 0,864; en los del mismo año, 0,658.» Los dos números están en el veredicto de la pantalla. De 26 a 19 palabras: unos 3 segundos.
- En la slide 9, sin el porqué del categórico:** «El mejor es Naive Bayes, en su versión categórica.» El número queda en pantalla y la razón, en las aclaraciones. Unos 7 segundos.
- En la slide 11, sin la ponderación por distancia:** se omite «Ponderar por distancia queda peor en todo el rango»; la curva punteada queda en pantalla, y la explicación, en las aclaraciones y en la pregunta 17. Unos 3 segundos.

No se recortan nunca: las limitaciones (slide 17); la slide 3, qué datos deciden (el consejo «Importante»); la 10, sobreajuste y subajuste (pedido por el punto 3.1); la 14, el número de test; y la 15 y la 16, los errores y los supuestos (punto 5). El hallazgo se acorta, pero no se omite: la última slide de contenido tiene que ser una figura (guía A6), y con los recortes 1 y 2 dura de todos modos unos 40 segundos.

La suma (gate G6). Las palabras habladas se cuentan como tokens separados por espacios, sin las marcas [→] ni los signos sueltos, y cada «?» del test cuenta como una palabra; en las slides 14 y 15 cuenta la variante más larga. Aplicada al guion del TP1, esta cuenta da 1 606 palabras, 26 menos (el 1,6 %) que las 1 632 que declaran sus 22 encabezados: siete coinciden y los otros quince declaran entre 1 y 4 palabras de más. Contado con esta regla, el TP1 dice 1 606 palabras en los 10:00 de su reloj, 2,68 por segundo: redondeado, el mismo 2,7.

- 1 364 palabras / 2,7 = 505,2 s = 8:25 ± 9:45.** Pasa, con 80 segundos de margen. Con las ventanas redondeadas a 5 segundos, el reloj termina en 8:30, 45 segundos antes que el esqueleto del plan. A 2,68 por segundo, 8:29.
- Con los números leídos completos: entre 8:47 y 8:52.** Los números de este guion tardan más en decirse que los del TP1, porque muchos son AUC con tres decimales. Se expandió cada número escrito con cifras a las palabras con que se lee («0,795» son seis: «cero coma setecientos noventa y cinco»), y cada «?» del test, como un número de tres decimales: cada palabra de este guion equivale a 1,19 palabras leídas, y cada una del TP1, a 1,15. A la velocidad de lectura que 2,7 por segundo le supone al TP1, este guion dura 8:47; si el TP1 se dijo en los 10:00 de su reloj, 8:52, 53 segundos por debajo del tope. Hay 80 números hablados, el 5,9 % de las palabras (en el TP1, 93, también el 5,8 %).
- Lo que decide son los dos ensayos cronometrados** (paso 8.4 del plan, gate G6): tienen que durar 10:00 o menos. Si un ensayo pasa de 9:45, se aplica el orden de recorte de arriba, en ese orden.

TRABAJO PRÁCTICO 2: CLASIFICACIÓN SUPERVISADA

¿Quién va a contratar un plazo fijo?

Grupo 7 — Andrés Cortese (64612) · Sebastián Caules (64331)
Instituto Tecnológico de Buenos Aires — 72.75 Aprendizaje Automático

Dataset: *Bank Marketing* — 41 188 contactos de campañas telefónicas de un banco, de 2008 a 2010
Defensa: 07/10/2026

1/20

(bloque 1, slides 1–3).

Buenas tardes. Grupo siete: Trabajo Práctico dos, clasificación supervisada sobre *Bank Marketing*.

A ACLARAR · PREGUNTAS PROBABLES

- **El 41 188 de la portada es el archivo entero:** la slide 3 lo muestra como «las 41 188 del archivo», antes de quitar los 12 duplicados exactos. Desde la slide 2, cada número dice de qué conjunto sale, con la tabla de la slide 3: train, validación o test.
- **El dataset es el del enunciado** (TP2, p. 1): el *Bank Marketing*, contactos de campañas telefónicas de un banco, de 2008 a 2010, como dice la portada.


2 · Decir siempre «no» ya acierta el 88,7 %

0:05 → 0:35 · ~87 palabras · 2 [→] · página 4 del PDF

Habla: Andrés

Decir siempre «no» ya acierta el 88,7 %

[El problema](#) · [Datos](#) · [EDA](#) · [Métricas](#) · [Modelos](#) · [Hiperparámetros](#) · [Modelo final](#) · [Conclusiones](#) · [Hallazgo](#)



EL PROBLEMA

2/20

Un banco ofrece un plazo fijo por teléfono. Antes de marcar, ¿este cliente va a contratar? Si lo sabemos, llamamos primero a los más probables.

[→] El modelo sólo puede usar lo que el banco sabe antes de la llamada: el cliente, su historial en campañas anteriores, el contexto económico y los datos de la llamada que va a hacer.

[→] Y la clase está muy desbalanceada: en train, sólo el 11,3 % dijo que sí. Decir siempre «no» ya acierta el 88,7 %, así que aquí la exactitud no sirve.

A ACLARAR · PREGUNTAS PROBABLES

- **Cuántos son:** 32 940 filas de train (slide 3), con 11,3 % de «yes» y 88,7 % de «no» (la barra de la figura). Decir siempre «no» acierta el 88,7 %: la exactitud no distingue un modelo de nada.
- **¿Qué variable no entra?** `duration`: se conoce al colgar, cuando el resultado ya se sabe (slide 4; D-05), y el pipeline la saca en las reglas fijas (slide 7, «sin duration»). Las demás son las de las cuatro cajas: lo que el banco sabe antes de marcar.
- **¿campaign existe antes de llamar?** Sí: es el «n.º de llamada» de la cuarta caja, la llamada que se va a hacer, contando esa. La reserva es una inferencia: si cada fila guarda el total de la campaña y, tras un «yes», no se vuelve a llamar, su valor final depende en parte del resultado. El efecto no se midió (D-07).
- **¿month, day_of_week y contact?** Son el mes, el día y el canal de la llamada que se va a hacer (la cuarta caja: «canal, mes, día»), y se eligen antes de marcar (inferencia).
- **Por qué el modelo ordena en lugar de clasificar con un umbral.** El enunciado habla de «priorizar recursos de marketing» (TP2, p. 1): lo que el banco necesita es a quién llamar primero, y por eso las dos métricas de la slide 8 miden el orden.
- **La exactitud engaña con clases desbalanceadas:** modelos con la misma exactitud cometen errores muy distintos (Clase 4, slides 26–27; D-19).

3 · Train decide; test sólo mide, y una sola vez

0:35 → 1:05 · punto de control · ~76 palabras · 3 [→] · página 8 del PDF

Habla: Andrés

Train decide; test sólo mide, y una sola vez

El problema · Datos · EDA · Métricas · Modelos · Hiperparámetros · Modelo final · Conclusiones · Hallazgo

41 176 filas: las 41 188 del archivo menos 12 duplicados exactos · 80/20 estratificado por y

train	test
32 940 filas · 80 %	8 236 filas · 20 %

ETAPA	DATOS	QUÉ DECIDE
EDA y ablaciones	train	qué variables entran, y cómo
validación cruzada	train, en 5 folds	modelo e hiperparámetros
evaluación final	test, una sola vez	nada: sólo estima el desempeño

DATOS

3/20

Es la regla de juego antes del primer número (guía A3) y el consejo «Importante» del enunciado. Se dice completa pero rápido: son definiciones que el tribunal ya conoce.

Primero, quitamos 12 duplicados exactos: si una copia cae en train y otra en test, el test deja de ser independiente. Después, 80/20 estratificado por la clase.

[→] El análisis exploratorio que decide y las ablaciones leen sólo train.

[→] La validación cruzada de 5 folds, también: con ella elegimos modelo e hiperparámetros.

[→] Y el test no decide nada: se abre una vez, al final, para estimar el desempeño. Por eso cada número dice de qué conjunto sale.

A ACLARAR · PREGUNTAS PROBABLES

- **Las cifras de la partición**, en la barra: 41 176 filas sin los 12 duplicados exactos; train 32 940 filas (80 %) y test 8 236 (20 %), estratificado por y.
- **¿Por qué estratificar, si no se vio en clase?** Con 11,3 % de «yes» (slide 2), una partición al azar sin estratificar puede dejar al test con otra proporción de «yes» sólo por la semilla, y el test se parecería menos a train por azar. Estratificar por y mantiene la misma proporción en los dos, y no cuesta nada.
- **¿Cómo se garantiza que nada mire el test?** Por diseño, y la tabla lo fija: el análisis exploratorio, las ablaciones y la validación cruzada leen sólo train; el test se usa una vez, al final, y no decide nada. Lo que se aprende de los datos se ajusta dentro de cada fold, sólo con el de entrenamiento (slide 7; pregunta 2).
- **Cada vuelta de la validación cruzada**, dentro de train, valida con uno de los 5 folds y ajusta con los otros cuatro.
- **Qué se evalúa en test:** el modelo elegido, Random Forest (slide 13), reentrenado con todo train. El reentrenamiento no está en pantalla: lo dice la charla de la slide 14, y es el paso que pide la cátedra una vez elegido el modelo (Clase 2, slides 88–89).
- **El orden importa** porque el enunciado lo pide: partir «antes de aplicar cualquier transformación que pueda producir data leakage» (TP2, p. 1).


4 · La duración predice el «yes», pero no existe antes de llamar

1:05 → 1:25 · ~58 palabras · 1 [→] · página 10 del PDF

Habla: Sebastián

La duración predice el «yes», pero no existe antes de llamar

El problema · Datos · EDA · Métricas · Modelos · Hiperparámetros · Modelo final · Conclusiones · Hallazgo



duration: fuera del modelo

EDA

4/20

(bloque 2, slides 4–7). Entra con la primera decisión del EDA.

Primera decisión del análisis exploratorio: la fuga. *duration* es la duración de la última llamada: se conoce al colgar, cuando el resultado ya se sabe. Medimos cuánto pesa, en validación: con *duration* los cuatro saltan, y Random Forest pasa de 0,770 a 0,939. Es un techo que no existe antes de llamar.

[→] Consecuencia: *duration* queda fuera del modelo.

A ACLARAR · PREGUNTAS PROBABLES

- **Con qué se midió:** los cuatro modelos de la figura, con y sin *duration*, en AUC de validación, media de 5 folds (el eje). Los saltos, anotados: Random Forest de 0,770 a 0,939, KNN de 0,755 a 0,911, SVM de 0,701 a 0,907 y Naive Bayes gaussiano de 0,768 a 0,831.
- **¿Por qué es fuga?** La duración de la llamada se conoce al colgar, cuando el «yes» ya se sabe, y el modelo decide antes de marcar (slide 2): ahí no existe. Por eso la leyenda la llama techo (D-05).
- **¿Por qué el AUC antes de la slide de métricas?** Porque ya es la métrica que decide: aquí se nombra, con su «sin modelo» en 0,5 (la línea punteada), y en la slide 8 se justifica junto con el recall.
- **¿Y las otras variables?** Son las de las cuatro cajas de la slide 2, que el banco conoce antes de marcar; *campaign*, el «n.º de llamada», con la reserva de la slide 2 (D-07).
- **¿Por qué medirla, si de todos modos sale?** Porque el enunciado sugiere comparar el modelo con y sin las variables problemáticas (TP2, p. 1), y porque el techo dice cuánto cuesta no tenerla.


5 · El archivo va por fecha: el «yes» sube de 1,9 % a 50,9 %

1:25 → 1:55 · ~79 palabras · 1 [→] · página 12 del PDF

Habla: **Sebastián**

El archivo va por fecha: el «yes» sube de 1,9 % a 50,9 %

El problema · Datos · **EDA** · Métricas · Modelos · Hiperparámetros · Modelo final · Conclusiones · Hallazgo



Partición aleatoria; la época va como limitación

EDA

5/20

Segunda: el archivo está ordenado por fecha, de mayo de 2008 a noviembre de 2010, y la tasa de «yes» no es estable. En train, en bloques de 2 000 filas, sube de 1,9 % a 50,9 %, mientras el euríbor se desploma.

[→] Consecuencia: partimos al azar —el enunciado plantea k-fold y no menciona el tiempo— y barajamos los folds, para que ninguno quede en una sola época. Lo que eso cuesta va como limitación, y es el hallazgo del final.

A ACLARAR · PREGUNTAS PROBABLES

- **Lo que muestra la figura, en train:** la tasa de «yes» por bloques de 2 000 filas, en el orden del archivo. En 2008 queda baja y pareja, siempre por debajo del 20 % del eje; la subida es de 2009 y 2010, hasta 50,9 %. La tasa por año no está en la figura.
- **El euríbor,** en el panel de abajo: por encima de 4 durante casi todo 2008 y por debajo de 2 desde el cambio a 2009. El contexto económico fecha las filas.
- **¿De dónde sale el año?** No viene en los datos, y por eso la figura dice «inferido». Se deduce de lo que se ve: el archivo va por fecha (el eje) y el mes sí es una variable (slide 2: «canal, mes, día»), así que cada vez que el mes retrocede empieza un año nuevo (inferencia desde el orden).
- **¿Por qué no partir por fecha?** El enunciado plantea k-fold y no menciona el tiempo, y con el último 20 % del archivo como test (la proporción de la slide 3) se entrenaría en una época y se evaluaría en otra: train quedaría casi entero en la época de tasa baja y test, en el final, donde la tasa sube (D-03).
- **¿Qué pasaba sin barajar?** Los folds se armarían en el orden del archivo, y cada uno quedaría en una época de la figura. Barajados, «cada fold mezcla las épocas» (slide 7; D-06).


6 · 999 no significa «nunca contactado»

1:55 → 2:10 · ~39 palabras · 1 [→] · página 14 del PDF

Habla: Sebastián

999 no significa «nunca contactado»

El problema · Datos · EDA · Métricas · Modelos · Hiperparámetros · Modelo final · Conclusiones · Hallazgo



pdays se queda: el 999 es un corte, no un número

EDA

6/20

Tercera: pdays. El 999 parece «no contactado antes», pero 3 302 filas con 999 sí tuvieron contactos previos, y los que tienen días registrados contratan el 64,6 %.

[→] Se queda: escalado o en un árbol, el 999 funciona como un corte.

A ACLARAR · PREGUNTAS PROBABLES

- **Las tres barras, en train**, cada una con su tasa de «yes» anotada: los nunca contactados (999 y previous = 0), los 3 302 con 999 pero con contactos previos, y los 1 207 con días registrados (pdays < 999), que contratan el 64,6 %. Las tasas de las dos primeras barras se señalan en pantalla, no se dictan.
- **Por qué 999 no es «nunca contactado»:** la barra del medio son filas con 999 y previous ≥ 1, es decir, contactadas antes, y su tasa queda por encima de la de los nunca contactados.
- **¿Por qué se queda?** Porque separa grupos que contratan muy distinto. Escalado o en un árbol, el 999 funciona como un corte, que es lo que dice el veredicto: el árbol lo aísla en una rama, y escalado queda como un extremo aparte (D-10).
- **¿Y una indicadora de contacto previo?** Ya la da el historial, que entra al modelo (slide 2: «campanas anteriores y su resultado»), y previous, que separa los dos grupos del 999, cuenta los contactos previos. Duplicarla pesaría doble en Naive Bayes y en las distancias de KNN.
- **¿Y los atípicos?** Con casi todas las filas en 999 (las dos primeras barras), el rango intercuartílico de pdays es cero: las 1 207 filas con días registrados son justo sus atípicos, y son las que más contratan. Por eso no se borran (slide 7).


7 · Todo se ajusta dentro de cada fold, en este orden

2:10 → 2:45 · punto de control · ~101 palabras · 4 [→] · página 19 del PDF

Habla: Sebastián

Todo se ajusta dentro de cada fold, en este orden

El problema · Datos · EDA · Métricas · Modelos · Hiperparámetros · Modelo final · Conclusiones · Hallazgo



Atípicos por IQR: 6 731 filas marcadas, ninguna eliminada

EDA

7/20

Las cajas entran en el orden en que el pipeline las ejecuta. El último overlay es la consecuencia del IQR, que es exactamente lo que la cátedra marcó como inconcluso en el TP1: se dice para qué sirvió, con su número, y que no se borró nada.

La partición: 5 folds estratificados y barajados, para que cada uno mezcle las épocas.

[→] Dentro de cada fold, reglas fijas: sale `duration`, `default` pasa a indicadora, se funden dos categorías raras y `unknown` queda como categoría; quedan 58 columnas.

[→] Después, la codificación de cada modelo: escalado para KNN y la SVM, deciles para Naive Bayes, ajustados sólo con el fold de entrenamiento.

[→] Los cuatro, en los mismos folds.

[→] Y los atípicos por IQR: sirven para diagnosticar, no para filtrar. Marcan 6 731 filas de train, y entre los de `pdays` el 64,6 % dijo que sí: son señal, no se borra ninguna.

A ACLARAR · PREGUNTAS PROBABLES

- **¿Qué hacen las reglas fijas?** Son las mismas en todos los folds y no aprenden nada de los datos: sacan `duration` (slide 4) y funden categorías; las columnas pasan de 62 a 58 (la caja).
- **¿Qué codificación lleva cada modelo?** «Según el modelo», dice la caja. KNN y la SVM miden distancias y necesitan escalar (Clase 8, slide 54; Alpaydın §8.3, p. 192); un árbol corta cada variable por separado, así que a Random Forest la escala no le cambia nada (D-12); y el Naive Bayes categórico trabaja con valores discretos, así que las numéricas se discretizan (D-18). Para los ceros del categórico, la corrección de Laplace: pregunta 13.
- **¿Cómo se decidió cada paso?** Con ablaciones sobre train (slide 3: «EDA y ablaciones»): cada una compara el modelo con y sin una decisión, como la de `duration` en la slide 4, con el AUC de validación, media de 5 folds (su eje).
- **Los atípicos** (D-17): la regla del IQR marca 6 731 filas de train con algún valor alejado, y no se borra ninguna. Entre los de `pdays`, que son las 1 207 filas con días registrados, el «yes» es 64,6 % (slide 6), contra 11,3 % en todo train (slide 2): borrarlos sacaría a los que más contratan. Sirven para diagnosticar, no para filtrar.
- **¿Y KNN sin escalar?** Sin escalar, en train, `pdays` es el 86,6 % de la varianza (slide 16): la distancia mediría casi sólo el historial de contacto, no clientes parecidos (pregunta 16).
- **¿Por qué barajar los folds?** Porque el archivo va por fecha (slide 5): sin barajar, cada fold quedaría en una época; barajados, «cada fold mezcla las épocas».
- **Sin fuga por construcción:** lo que se aprende de los datos —escalas, cortes— se ajusta dentro de cada fold, sólo con el de entrenamiento (la caja punteada), que es lo que pide el enunciado (TP2, p. 1).

8 · Dos métricas que no premian decir siempre «no»

2:45 → 3:20 · ~83 palabras · 2 [→] · página 22 del PDF

Habla: Andrés

Dos métricas que no premian decir siempre «no»

El problema · Datos · EDA · Métricas · Modelos · Hiperparámetros · Modelo final · Conclusiones · Hallazgo

PARA COMPARAR Y ELEGIR

AUC

¿ordena bien a los clientes?

sin modelo: 0,500

PARA MEDIR EL USO REAL

recall al 20 %

¿qué parte de los «yes» alcanzan las llamadas?

sin modelo: 0,200

La exactitud no se usa: decir siempre «no» ya da 88,7 %

MÉTRICAS

8/20

(bloque 3, slides 8–12). Es teoría de la Clase 4: se nombra, no se desarrolla. Lo propio es el 20 % y por qué no se usa la exactitud.

Falta la vara: dos métricas de la Clase 4. El AUC mide si el modelo ordena bien a quién llamar, sin depender de un umbral; sin modelo vale 0,5. Con ella comparamos y elegimos, siempre en validación.

[→] La segunda es el uso real: si el banco llama al 20 % de la lista con mayor puntaje, ¿qué parte de los que contratarían alcanza? Cuenta el error caro, el cliente perdido; sin modelo vale 0,200.

[→] La exactitud, no: decir siempre «no» ya da el 88,7 %.


A ACLARAR · PREGUNTAS PROBABLES

- **Las citas:** el AUC, Clase 4, slides 45–51; el umbral «depende del costo de cada error», slides 41–44; tres modelos con la misma exactitud cometen errores distintos, slides 26–27; precisión y recall, slides 30–31 (D-19).
- **Lo que el AUC no hace:** no premia decir siempre «no» (un puntaje constante da 0,500) y no depende del umbral. Por eso sirve para ordenar a quién llamar, que es priorizar recursos (TP2, p. 1).
- **«Sin modelo»** es un puntaje igual para todos: no ordena, así que su AUC es 0,500, y llamar al 20 % de la lista al azar alcanza al 20 % de los «yes»: recall 0,200. Es el mismo rótulo en todas las slides que comparan con una línea de base; la slide 14 no compara, y la slide 15 tampoco cuando muestra el test.
- **¿Por qué no el umbral de la Clase 4, el punto de la ROC más cercano a la esquina superior izquierda** (slide 52)? Es simétrico entre los dos errores, y aquí no cuestan lo mismo; y con un umbral por modelo los recalls no se comparan. Con el 20 % de la lista, todos los modelos hacen las mismas llamadas (D-20).
- **¿Por qué el 20 %?** Es un supuesto de negocio, declarado como limitación (slide 17), y la mejora propuesta es un costo por tipo de error en lugar del 20 % fijo (pregunta 8).
- **¿Y F_1 o la precisión?** Con el 20 % fijo, las llamadas ya están dadas: precisión, recall y F_1 crecen los tres con los «yes» alcanzados, así que ordenan igual a los modelos (cuenta nuestra, con las definiciones de la Clase 4, slides 30–31). Sin modelo, la precisión es la proporción de «yes», el 11,3 % de train (slide 2).
- **¿Y el desbalance?** No se remuestrea: el pipeline de la slide 7 no tiene ese paso, y estas dos métricas no premian el «no» (D-21; pregunta 9).

9 · Sin ajustar, gana Naive Bayes: 0,782 contra 0,500 sin modelo

3:20 → 3:45 · ~74 palabras · sin [→] · página 23 del PDF

Habla: Andrés



Son tres los que sobreajustan: también KNN con $k = 15$, que es el puente a la slide 11, donde sobreajusta el k pequeño.

Primero, los modelos con hiperparámetros de referencia: en AUC de validación, todos quedan muy por encima de sin modelo. El mejor es Naive Bayes en su versión categórica: discretizar las numéricas en deciles le suma 0,013 sobre el gaussiano, porque las numéricas están lejos de ser normales. Y tres sobreajustan: Random Forest sin límite de profundidad, la SVM con RBF y KNN con $k = 15$. Lo muestran, y lo corrigen, las curvas que siguen.

A ACLARAR · PREGUNTAS PROBABLES

- **Qué es «sin ajustar»:** cada modelo con valores de referencia de sus hiperparámetros, antes de las curvas de las slides 10–12, que eligen uno por modelo.
- **Categórico contra gaussiano (D-18):** 0,782 contra 0,769 de AUC de validación. El gaussiano supone una normal por clase, y las numéricas están lejos de serlo: pdays, por ejemplo, es casi binaria, con casi todas las filas en 999 (slide 6). El categórico discretiza las numéricas y no supone ninguna forma (Clase 6, slide 46; pregunta 13).
- **¿Cuánto sobreajustan?** La figura sólo muestra validación; la brecha con train se ve en las curvas de las slides 10–12: Random Forest sin límite de profundidad, con train en el tope del eje; KNN en $k = 15$, una de las marcas del eje de la slide 11, con train bien por encima de validación; la SVM con RBF y un C grande.
- **¿Por qué Random Forest da 0,770 en la slide 4 y 0,772 aquí?** Son dos mediciones de validación distintas. La de la slide 4 es del análisis exploratorio (su sección en la barra es «EDA», y en la slide 3 el EDA decide «qué variables entran, y cómo»); la de la 9 viene después del pipeline de la slide 7. Que la primera sea anterior a ese pipeline completo es inferencia por el orden de las slides, y qué cambió exactamente entre una y otra no está en pantalla. Lo mismo la SVM, 0,701 y 0,702, y el Naive Bayes gaussiano, 0,768 y 0,769; KNN da 0,755 en las dos.
- **«Muy por encima» de sin modelo:** el mejor, 0,782, y el peor, la SVM, 0,702, contra 0,500 (el título).
- **Las barras** son ± 1 desvío entre los 5 folds (el eje).


10 · ¿Desde qué profundidad sobreajusta Random Forest?

3:45 → 4:20 · ~98 palabras · 2 [→] · página 26 del PDF

Habla: Andrés

¿Desde qué profundidad sobreajusta Random Forest?

El problema · Datos · EDA · Métricas · Modelos · **Hiperparámetros** · Modelo final · Conclusiones · Hallazgo



HIPERPARÁMETROS

10/20

Es el punto 3.1 que el enunciado pide decir en la presentación: sobreajuste y subajuste en una curva. Tres pasos, con el mismo encuadre: no apurarla.

Esta es la curva para discutir sobreajuste: la profundidad máxima de los árboles. En train el AUC sube siempre, y sin límite llega a 1,000: los árboles memorizan.

[→] La validación, en cambio, sube hasta profundidad 10 y después baja, hasta 0,772 sin límite: la brecha se abre a 0,228. Eso es sobreajuste. En el otro extremo, con profundidad 2, train y validación casi empatan, y los dos quedan bajos: el modelo es demasiado simple, subajuste.

[→] Elegimos 8: queda dentro de un error estándar del máximo y es más simple. En validación da 0,795, con una brecha de 0,030.

A ACLARAR · PREGUNTAS PROBABLES

- **¿Por qué 8 y no 10, si ahí la validación es un poco más alta?** Por la regla que dice la charla: no se elige el máximo, sino el más simple de los que quedan dentro de un error estándar de él (D-22). Cerca del máximo la curva es casi plana, y 8 queda dentro.
- **¿Y por qué no 6, que se ve casi igual?** Si 6 hubiera quedado dentro de ese umbral, la regla lo habría elegido, porque es más simple. La estrella en 8 dice que quedó fuera, por poco: en la figura, 6 está apenas por debajo de 8. Con la banda no se puede ver dónde pasa el umbral (la viñeta siguiente).
- **La banda no es el error estándar:** es ± 1 desvío entre los 5 folds; el error estándar es ese desvío dividido por la raíz de 5, más angosto, y el umbral de la regla no está dibujado.
- **¿De dónde sale la regla?** No está en las slides de la cátedra. La Clase 3 advierte que elegir el mejor entre muchas estimaciones con ruido también elige ruido favorable (slides 98–100), y la regla lo atenúa porque no elige el máximo (D-22). Viene de los árboles CART de Breiman y otros, y está en Hastie, Tibshirani y Friedman, *The Elements of Statistical Learning*, §7.10.1: fuera de la bibliografía de la materia.
- **El protocolo** es el de la Clase 7, slide 50: el AUC en train y en validación con los 5 folds, la brecha entre los dos y la curva.
- **La brecha** es la distancia entre train y validación en la misma profundidad: con 8, 0,030 (anotada). A la derecha se abre: train llega al tope del eje, 1,00, y la validación baja («sobreajuste →»).
- **El subajuste:** con profundidad 2, train y validación casi coinciden, y los dos quedan por debajo del 0,795 de la profundidad 8: el modelo es demasiado simple («← subajuste»).
- **¿Y el número de árboles?** No es un eje de complejidad: más árboles no cambian el sesgo y sólo bajan la varianza (Clase 7, slide 61; pregunta 19).


11 · En KNN sobreajusta el k pequeño: se elige k = 801

4:20 → 4:45 · ~62 palabras · sin [→] · página 27 del PDF

Habla: Andrés

En KNN sobreajusta el k pequeño: se elige k = 801

El problema · Datos · EDA · Métricas · Modelos · **Hiperparámetros** · Modelo final · Conclusiones · Hallazgo



HIPERPARÁMETROS

11/20

En KNN el eje va al revés. Con un vecino, train da 0,988 y validación 0,619: cada cliente es su propio vecino, sobreajuste puro. Al sumar vecinos la brecha se cierra, y desde 151 todo queda dentro de un error estándar del mejor; tomamos el más suave, 801, con una brecha de 0,006. Ponderar por distancia queda peor en todo el rango.

A ACLARAR · PREGUNTAS PROBABLES

- **El elegido, en validación:** k = 801, con AUC 0,784 y brecha con train 0,006 (anotados).
- **¿Dónde está el máximo?** La validación forma una meseta en los k grandes: desde 151 casi no cambia. Entre los que empatan con el mejor, la regla de un error estándar de la slide 10 toma el más suave, el de más vecinos.
- **¿No es enorme k = 801?** Cada fold entrena con cuatro quintos de las 32 940 filas de train (slide 3), y el «yes» es el 11,3 % (slide 2): estimar bien una proporción baja pide muchos vecinos (inferencia). Y está en el borde de la grilla: pregunta 18.
- **¿Y ponderar por distancia?** (Mitchell §8.2.1). Es la línea punteada: en train queda en 1,0, porque cada punto de train se encuentra a sí mismo a distancia cero; en validación, con más de un vecino, queda por debajo de la uniforme en todo el rango (con uno, las dos coinciden).
- **El eje es logarítmico** porque la grilla va de 1 a 801.
- **¿Por qué train no llega a 1,0 con un vecino?** Si cada fila de train fuera única, con un vecino se encontraría a sí misma y train daría 1,0. Que quede apenas por debajo indica filas con las mismas predictoras y distinta respuesta, que empatan a distancia cero (inferencia; pregunta 7).
- **Escalar no es opcional en KNN:** mide distancias (Clase 8, slide 54; Alpaydin §8.3, p. 192).


12 · La SVM queda lineal y muy regularizada: $C = 0,001$

4:45 → 5:05 · ~55 palabras · 1 [→] · página 29 del PDF

Habla: Andrés

La SVM queda lineal y muy regularizada: $C = 0,001$

El problema · Datos · EDA · Métricas · Modelos · **Hiperparámetros** · Modelo final · Conclusiones · Hallazgo



En la SVM exploramos C y el kernel. Con kernel lineal la curva de C es plana, sin sobreajuste, y tomamos 0,001, el más regularizado.

[→] Con RBF, en cambio, un C grande sobreajusta: train sube casi a uno y la validación cae. Y ni en su mejor C el RBF supera al lineal: queda lineal.

A ACLARAR · PREGUNTAS PROBABLES

- **¿Qué es C ?** El costo de las violaciones del margen: un C grande castiga más y regulariza menos, como dice el eje (Clase 8, slide 49; pregunta 14).
- **El elegido:** $C = 0,001$, con AUC 0,774 de validación y brecha con train 0,002 (anotados). Con kernel lineal la curva es plana: 0,001 y 0,01 quedan a la misma altura, y se toma el más regularizado. Es el menor C del eje: pregunta 18.
- **El RBF sobreajusta con C grande:** la línea punteada de train sube casi a uno y la de validación cae («sobreajuste con RBF →»).
- **¿El RBF no mejora al lineal en ningún C ?** Su mejor valor de validación, 0,772 en su mejor C (slide 16), no alcanza el 0,774 del lineal elegido.
- **¿Y γ ?** La curva del RBF varía sólo C , con γ fijo (el eje). El kernel elegido es el lineal, que no tiene γ ; la grilla conjunta de C y γ es la de la Clase 8, slides 48–49.


13 · Ajustados, gana Random Forest por 0,011 de AUC en validación

5:05 → 5:25 · punto de control · ~60 palabras · sin [→] · página 30 del PDF

Habla: Sebastián

Ajustados, gana Random Forest por 0,011 de AUC en validación

El problema · Datos · EDA · Métricas · Modelos · Hiperparámetros · **Modelo final** · Conclusiones · Hallazgo



MODELO FINAL

13/20

(bloque 4, slides 13–17). Entra con el resultado de la selección.

Con los hiperparámetros elegidos gana Random Forest: en validación, 0,795 de AUC y 0,629 de recall llamando al 20 %. Le siguen KNN, Naive Bayes y la SVM, en ese orden, y ninguno queda dentro de un error estándar de Random Forest. Pero importa la escala: entre el mejor y el peor hay 0,021; entre Random Forest y sin modelo, 0,295.

A ACLARAR · PREGUNTAS PROBABLES

- **Los cuatro, en AUC de validación** (anotados en la figura): Random Forest 0,795, KNN 0,784, Naive Bayes 0,782 y SVM 0,774. En recall de validación, llamando al 20 % de la lista: 0,629, 0,617, 0,614 y 0,614.
- **La escala:** los cuatro van de 0,774 a 0,795, y sin modelo es 0,5 (la línea punteada); Random Forest le saca 0,011 a KNN (el título).
- **¿Y si hubiera empate?** No lo hubo: ninguno quedó dentro de un error estándar de Random Forest (lo dice la charla, con la regla de la slide 10), y Random Forest es primero también en recall: 0,629 contra 0,617 de KNN (anotados).
- **¿Sobreajusta?** Su brecha con train es 0,030 (slide 10, la profundidad 8).
- **¿Cuánto sumó ajustar?** En AUC de validación, contra la slide 9: Random Forest de 0,772 a 0,795, KNN de 0,755 a 0,784 y la SVM de 0,702 a 0,774. Naive Bayes no tiene curva en las slides 10–12: queda en 0,782.
- **¿Y la precisión?** Con el 20 % fijo ordena a los modelos igual que el recall (aclaraciones de la slide 8). Mientras el test siga cerrado, se ve además como su inversa en la slide 15: 2,8 llamadas por cada «yes» alcanzado, contra 8,9 sin modelo (validación). Con el test evaluado, la slide 15 muestra en su lugar el recall de test, y esos dos valores ya no están en pantalla.

14 · ¿Qué AUC esperar en clientes nuevos de la misma época?

5:25 → 5:55 · ~72 palabras · sin [→] · página 31 del PDF

Habla: Sebastián

¿Qué AUC esperar en clientes nuevos de la misma época?

[El problema](#) · [Datos](#) · [EDA](#) · [Métricas](#) · [Modelos](#) · [Hiperparámetros](#) · [Modelo final](#) · [Conclusiones](#) · [Hallazgo](#)

AUC DE TEST

pendiente: se evalúa una vez, después del 30/09

MODELO FINAL

14/20

Es la única slide que no compara nada (guía C2, C3): ni «sin modelo» ni otro modelo, ni en pantalla ni en voz alta. La comparación con validación se dice, no se proyecta (C6). Los «?» se leen de *informe/numeros.md*, sección «Números de test», después de evaluar.

MIENTRAS EL TEST SIGA CERRADO (ensayos hasta el 01/10), en lugar de la variante de abajo, en gris:

¿Qué esperar en clientes nuevos? Lo va a decir el test: Random Forest reentrenado con todo train, sobre las 8 236 filas de test, una sola vez. Todavía no lo abrimos: lo haremos después de las respuestas de la cátedra. Y atención a qué va a medir: el test sale de las mismas campañas que train, así que estima clientes nuevos de esa época, no una campaña futura. Eso es el hallazgo.

Con el test evaluado, en la defensa, en lugar de lo anterior:

¿Qué esperar en clientes nuevos? Lo dice el test: Random Forest reentrenado con todo train, sobre las 8 236 filas de test, una sola vez. Da ? de AUC, con un intervalo del 95 % de ?. Contra validación, la diferencia es ?. Y atención a qué mide: el test sale de las mismas campañas que train, así que estima clientes nuevos de esa época, no una campaña futura. Eso es el hallazgo.

El encabezado cuenta la variante más larga.

A ACLARAR · PREGUNTAS PROBABLES

- **¿Por qué una sola vez?** Si el test se mira más de una vez y algo cambia en el medio, deja de ser independiente: pasa a decidir, y la tabla de la slide 3 dice que no decide nada. Por eso se evalúa una vez («test, una sola vez», en esa tabla), con todo lo demás cerrado (N0-1; pregunta 1). Mientras siga cerrado, la slide dice además cuándo: «después del 30/09».
- **Qué mide:** Random Forest reentrenado con todo train, sobre las 8 236 filas de test (slide 3): clientes nuevos de las mismas campañas, no de una campaña futura (slide 17). El reentrenamiento no está en pantalla: lo dice la charla, y es el paso de la Clase 2, slides 88–89.
- **El intervalo** (con el test evaluado, en la slide): cuánto variaría el AUC de test con otra muestra de clientes nuevos de la misma época; es la incertidumbre de medir sobre un solo test.
- **¿Por qué no aparece «sin modelo»?** Porque el test no compite con nada: «sólo estima el desempeño» (slide 3). Una línea de base al lado lo haría parecer una comparación que decide algo.
- **Cómo leer la diferencia con validación** (se dice, no se proyecta): se nombran los dos valores, el AUC de test y el 0,795 de validación (slide 13), y la distancia se lee contra la variación entre folds de validación (la barra de ± 1 desvío de la slide 18) y contra el intervalo de test. Dentro de esa variación es ruido, en cualquier sentido; si además da algo más bajo, es coherente con el optimismo de haber elegido los hiperparámetros con la misma validación (slide 17), que no medimos (pregunta 10). Una diferencia mayor ya no la explica el ruido: obliga a revisar la partición o el pipeline, y se dice (pregunta 27). En ningún caso se cambia el modelo después: lo que se promete es el número de test.

15 · El error caro es el «yes» que no se llama

5:55 → 6:20 · ~72 palabras · 2 [→] · página 34 del PDF

Habla: Sebastián

El error caro es el «yes» que no se llama

El problema · Datos · EDA · Métricas · Modelos · Hiperparámetros · **Modelo final** · Conclusiones · Hallazgo

validación (OOF): los 5 folds juntos
llamando al 20 % de la lista completa: 6 588 llamadas

	LLAMADO	NO LLAMADO
«yes»	2 329 «yes» alcanzados	1 382 «yes» perdidos
«no»	4 259 llamadas de más	24 970 bien descartados

- **1 382 «yes» sin llamar:** el error caro
- **2,8** llamadas por cada «yes» sin modelo: 8,9

MODELO FINAL

15/20

MIENTRAS EL TEST SIGA CERRADO, la matriz de la slide es la de validación, y se dice:

¿Qué errores comete? Con el test cerrado, la matriz es la de validación: los puntajes fuera de fold, llamando al 20 % de la lista. Un falso positivo es una llamada de más; un falso negativo, un cliente que habría contratado y no se llama: ese es el caro.

[→] Quedan 1 382 «yes» sin llamar, sobre todo de 2008 y sin historial.

[→] Aun así, cada «yes» cuesta 2,8 llamadas, contra 8,9 sin modelo.

Con el test evaluado, en la defensa, en lugar de lo anterior:

¿Qué errores comete? Es la matriz de test, llamando al 20 % de la lista. Un falso positivo es una llamada de más; un falso negativo, un cliente que habría contratado y no se llama: ese es el caro.

[→] Quedan ? «yes» de test sin llamar. En validación, los perdidos eran sobre todo de 2008 y sin historial.

[→] El recall de test, llamando al 20 %, es ?.

El encabezado cuenta la variante más larga.

A ACLARAR · PREGUNTAS PROBABLES

- **¿Qué es fuera de fold (OOF)?** (Con el test cerrado: la slide dice «validación (OOF)».) Cada fila de train puntuada por el modelo del fold en el que no entrenó: toda train, sin fuga.
- **La matriz de validación** (con el test cerrado): 2 329 «yes» alcanzados, 1 382 perdidos, 4 259 llamadas de más y 24 970 bien descartados, llamando al 20 % de la lista completa, 6 588 llamadas.
- **¿Por qué la lista completa y no fold por fold?** (Con el test cerrado: la slide dice «la lista completa».) Los puntajes fuera de fold de los 5 folds se juntan en una sola lista y se corta su 20 %: es el mismo corte que se aplica al test, el 20 % de su lista. Con el test evaluado, la slide corta el 20 % de la lista de test («llamando al 20 % de la lista»), y la pregunta no se plantea.
- **El costo por «yes», en validación** (con el test cerrado): 2,8 llamadas es $(2\,329 + 4\,259) / 2\,329$, las llamadas sobre los «yes» alcanzados; sin modelo, 8,9 es la inversa de la proporción de «yes», el 11,3 % de train (slide 2). Con el test evaluado, la slide muestra en su lugar el recall de test: el costo por «yes» de test no está impreso y no se calcula en vivo; se nombran las llamadas y los «yes» alcanzados de la matriz.
- **¿Quiénes son los perdidos?** La slide no los desglosa, y se dice así. Lo que se ve lo hace esperable (inferencia): en 2008 el modelo ordena poco aun barajado, de 0,519 a 0,584 (slide 19), y el 86,3 % de train no tiene campaña previa (slide 17).
- **Por qué el falso negativo es el caro:** una llamada de más cuesta una llamada; un cliente perdido es un plazo fijo que no se contrata. Es el costo desigual de la Clase 4, slides 41–44.
- **Con el test evaluado**, la matriz es la de test, con el 20 % de su lista, y al lado su recall; no se compara con «sin modelo», como en la slide 14.

16 · ¿Por qué ganó Random Forest y quedó última la SVM?

6:20 → 7:00 · ~107 palabras · 3 [→] · página 38 del PDF

Habla: **Sebastián**

¿Por qué ganó Random Forest y quedó última la SVM?

El problema · Datos · EDA · Métricas · Modelos · Hiperparámetros · Modelo final · Conclusiones · Hallazgo

Random Forest · 0,795

no supone escala ni forma; es el que más pierde sin macro ni month: -0,059

Naive Bayes · 0,782

supone independencia: tres macro con r de 0,91 a 0,97

KNN · 0,784

mide distancias: sin escalar, pdays es el 86,6 % de la varianza

SVM · 0,774

quedó lineal: el RBF no la mejora (0,772 en su mejor C)

AUC de validación · sin modelo: 0,500

CONCLUSIONES

16/20

Son los cuatro ejemplos del enunciado (TP2, p. 2): variables muy correlacionadas y distribuciones no gaussianas (Naive Bayes), diferencias de escala (KNN, SVM) y relaciones no lineales (RF, SVM). Como las fichas del deck, cada modelo lleva un supuesto y un efecto medido, y ninguna frase da una causa del orden como probada: la U de la edad se mezcla con la época, y no se midió qué pierde cada modelo sin la edad.

¿Por qué rindió cada uno? Por sus supuestos. Random Forest no supone escala ni forma, y es el que más pierde sin las variables de época: 0,059 en validación. Que gane por reconocer la época es inferencia.

[→] KNN mide distancias: sin escalar, en train, pdays tiene el 86,6 % de la varianza.

[→] Naive Bayes supone independencia, y en train el bloque macro la viola, con correlaciones de 0,91 a 0,97; como las numéricas no son normales, el categórico le gana al gaussiano.

[→] La SVM quedó lineal: el RBF no la mejora. Por qué queda última no lo medimos; entre los cuatro hay sólo 0,021 de AUC en validación.

A ACLARAR · PREGUNTAS PROBABLES

- **¿Qué pierde Random Forest sin las variables de época?** Sin el bloque macro ni month, 0,059 de AUC de validación (la tarjeta), y es el que más pierde de los cuatro (D-25). Que gane por reconocer la época es inferencia; lo retoma el hallazgo (slides 18–19). No medimos importancias de variables.
- **¿Por qué también month?** En un archivo ordenado por fecha (slide 5), el mes también fecha las filas (inferencia).
- **¿Por qué el bloque macro no arruina a Naive Bayes, si viola la independencia?** Tres de sus variables tienen, en train, correlaciones de 0,91 a 0,97: es casi la misma información tres veces. Eso lleva las probabilidades a los extremos, pero no necesariamente cambia el orden, que es lo que mide el AUC (inferencia; pregunta 12).
- **¿Por qué queda última la SVM?** No lo medimos. Lo que se ve: el RBF, que podría captar relaciones no lineales, no mejora al lineal, 0,772 de AUC de validación en su mejor C contra 0,774 (el pie de la slide); y la distancia con los demás es pequeña: los cuatro van de 0,774 a 0,795.
- **Las escalas:** sin escalar, en train, pdays sola es el 86,6 % de la varianza; la distancia de KNN miraría casi sólo esa variable. Por eso se escala dentro de cada fold (slide 7).
- **Las distribuciones no gaussianas:** pdays es casi binaria, con casi todas las filas en 999 (slide 6); por eso el Naive Bayes del TP es el categórico, que le gana al gaussiano (slide 9).

17 · Limitaciones: el test mide estas campañas, no una futura

7:00 → 7:30 · punto de control · ~86 palabras · 1 [→] · página 40 del PDF

Habla: Sebastián

Limitaciones: el test mide estas campañas, no una futura

El problema · Datos · EDA · Métricas · Modelos · Hiperparámetros · Modelo final · Conclusiones · Hallazgo

LIMITACIONES

La época: el test es de las mismas campañas

Llamar al 20 % es un supuesto de negocio

Hiperparámetros elegidos con la misma validación

QUÉ MEJORARÍAMOS

Validar hacia adelante en el tiempo

Más historial: el 86,3 % no tiene campaña previa

Un costo por tipo de error, no un 20 % fijo

CONCLUSIONES

17/20

Antes del hallazgo, siempre (guía A4, A7). Nunca se recorta.

Tres limitaciones, por impacto. La época: el test sale de las mismas campañas, así que vale para clientes nuevos de esas campañas, no para una futura. Llamar al 20 % es un supuesto. Y elegimos los hiperparámetros con la misma validación que los reporta: el máximo sale algo optimista.

[→] Lo primero que haríamos es validar hacia adelante en el tiempo, que es como se usaría el modelo. Después, sumar historial: el 86,3 % de train no tiene campaña previa. Y un costo por tipo de error, en lugar del 20 %.

A ACLARAR · PREGUNTAS PROBABLES

- **¿Cuánto optimismo?** No lo medimos: haría falta una validación cruzada anidada (Clase 3, slides 98–100; D-22), y aquí ese papel lo cumple el test, que se abre una vez (slide 3; pregunta 10). La regla de un error estándar lo atenúa, porque no elige el máximo: profundidad 8 y no 10 (slide 10).
- **¿Y dentro de una campaña?** El 0,795 y el 0,629 de validación (slide 13) ordenan una lista que mezcla las épocas; en los pares «yes»–«no» del mismo año, el AUC baja a 0,658 (slide 18; pregunta 24).
- **¿Por qué validar hacia adelante es lo primero?** Porque es como se usaría el modelo: entrenado con el pasado, para una campaña futura. Lo que cambia se ve en el hallazgo (slides 18–19).
- **«Más historial»:** el 86,3 % de train no tiene campaña previa, y el historial separa mucho: con días registrados, el «yes» es 64,6 % (slide 6), contra 11,3 % en todo train (slide 2).
- **¿Y duration?** Con ella, Random Forest llega a 0,939 de AUC de validación, pero no existe antes de llamar (slide 4).
- **Otra mejora:** calibrar las probabilidades, porque un costo por tipo de error necesita probabilidades y hoy las dos métricas sólo miden el orden (slide 8; inferencia).


18 · Entrenado con el pasado, Random Forest cae de 0,795 a 0,558

7:30 → 7:55 · ~65 palabras · 1 [→] · página 42 del PDF

Habla: Andrés

Entrenado con el pasado, Random Forest cae de 0,795 a 0,558

El problema · Datos · EDA · Métricas · Modelos · Hiperparámetros · Modelo final · Conclusiones · Hallazgo



Barajado, AUC 0,864 en pares «yes»–«no» de años distintos y 0,658 en los del mismo año

HALLAZGO

18/20

(bloque 5, slides 18–20). Entra enganchado con la última frase de Sebastián: validar hacia adelante.

El hallazgo. Validamos hacia adelante dentro de train: cada fold entrena con el pasado y valida con el bloque siguiente. Barajados, los cuatro están entre 0,774 y 0,795; hacia adelante, ninguno pasa de 0,598, y Random Forest cae a 0,558.

[→] ¿Por qué tanto? Parte del 0,795 es distinguir años: en los pares «yes»–«no» de años distintos, el AUC es 0,864; en los del mismo año, 0,658.

A ACLARAR · PREGUNTAS PROBABLES

- **¿Cómo se validó hacia adelante?** Con train ordenado por fecha y partido en bloques: cada fold valida con un bloque y entrena con todos los anteriores (la leyenda de la slide 19), y son los cinco bloques de esa slide (D-25). Todo dentro de train: el test no participa (slide 3).
- **Los cuatro, en AUC de validación:** barajados, 0,795, 0,784, 0,782 y 0,774; hacia adelante, Random Forest 0,558, KNN 0,539, Naive Bayes 0,598 y SVM 0,541.
- **¿Por qué no Naive Bayes, si hacia adelante da 0,598?** El modelo se elige con la validación cruzada de la slide 3, barajada (slide 7), y ahí gana Random Forest (slide 13). Hacia adelante, las barras de ± 1 desvío de los cuatro se superponen (el eje dice «media ± 1 desvío entre folds»), así que no hay un ganador claro. Validar así es la primera mejora (slide 17).
- **¿Por qué la barra hacia adelante es tan ancha?** Porque el modelo sirve en dos bloques y en tres no (slide 19): los tres de 2008 dan de 0,426 a 0,500, y los de 2009–2010, 0,664 y 0,711. No es la tasa de «yes» de cada bloque, que va de 4,7 % a 35,2 %: el AUC no depende de ella, porque la ROC calcula cada tasa dentro de su clase (Clase 4, slides 45–51). Y no es sólo entrenar con poco pasado: 2008 cuesta ordenarlo aun barajado, en las mismas filas, de 0,519 a 0,584, contra 0,748 y 0,762 en 2009–2010.
- **¿Y para elegir a quién llamar dentro de una campaña?** Es la pregunta 24.
- **La cuenta de los pares:** el AUC es la proporción de pares «yes»–«no» bien ordenados (Clase 4, slides 45–51). El veredicto separa los pares por año, con los puntajes barajados de validación: 0,864 entre años distintos y 0,658 dentro del mismo año. No es entrenar en un año y validar en otro: eso lo mide la validación hacia adelante.
- **Por qué los pares entre años son fáciles:** la tasa de «yes» cambia mucho con la época, de 1,9 % a 50,9 % en los bloques de la slide 5; basta con reconocer la época para ordenar bien un «yes» de 2010 frente a un «no» de 2008 (inferencia).


19 · En 2008 no sirve; en 2009–2010 pierde, pero no cae al azar

7:55 → 8:25 · ~71 palabras · 1 [→] · página 44 del PDF

Habla: Andrés

En 2008 no sirve; en 2009–2010 pierde, pero no cae al azar

El problema · Datos · EDA · Métricas · Modelos · Hiperparámetros · Modelo final · Conclusiones · Hallazgo



HALLAZGO

19/20

Es lo último que se muestra (guía A6). Si el reloj va atrasado, el segundo paso se reduce a la frase de recorte del «Reloj de ensayo».

Bloque a bloque: en los tres bloques de 2008, hacia adelante no pasa de 0,5, y en el tercero, 0,426, el orden incluso se invierte.

[→] Pero barajado, en esas mismas filas, tampoco pasa de 0,584: en 2008 el modelo no sirve ni mezclando épocas. En los dos bloques de 2009–2010, en cambio, pierde 0,084 y 0,051: una caída real, pero no al azar. Por eso el test vale para estas campañas.

A ACLARAR · PREGUNTAS PROBABLES

- **Hacia adelante, bloque a bloque** (anotado en la figura): 0,489, 0,500, 0,426, 0,664 y 0,711.
- **Barajado, en las mismas filas** (el AUC fuera de fold de Random Forest en las filas de cada bloque): 0,536, 0,519, 0,584, 0,748 y 0,762. Bloque a bloque, hacia adelante contra barajado: 0,489 y 0,536; 0,500 y 0,519; 0,426 y 0,584; 0,664 y 0,748; 0,711 y 0,762.
- **Los bloques** (las etiquetas del eje): mayo–julio, julio–agosto y agosto–noviembre de 2008; noviembre de 2008 a mayo de 2009; mayo de 2009 a noviembre de 2010. El «yes» de cada uno: 4,7 %, 6,5 %, 5,6 %, 12,7 % y 35,2 %.
- **¿0,426 es azar?** Queda por debajo de 0,5, así que en ese bloque el orden sale invertido: un AUC por debajo de 0,5 ordena al revés, el «mal» clasificador de la Clase 4 (slides 45–51). Pero es un solo bloque y sin intervalo, así que no decimos a cuántos errores estándar queda de 0,5: es un indicio, no una prueba de que sea peor que el azar.
- **¿Es sólo que las variables macro fechan las filas?** En parte. Si el modelo sólo reconociera la época, frente a una nueva ordenaría como el azar, cerca de 0,5, y eso dan los dos primeros bloques de 2008, 0,489 y 0,500. En el tercero da 0,426, por debajo de sin modelo: el orden se invierte, y eso sugiere que la relación entre las variables y el «yes» cambia con el tiempo (inferencia). Es un solo bloque y sin intervalo: un indicio, no una prueba. Barajado, sacar el bloque macro y month sí le cuesta a Random Forest 0,059 (slide 16): reconocer la época ayuda cuando las épocas se mezclan.
- **¿Por qué no validar así desde el principio?** El enunciado plantea k-fold; un esquema temporal habría entrenado con la época de tasa baja para predecir la de tasa alta: los bloques de 2008 tienen de 4,7 % a 6,5 % de «yes», y el último, 35,2 % (D-25). Es la primera mejora (slide 17).
- **Qué significa para el banco:** el número de test valdrá para clientes nuevos de estas campañas. Para una campaña futura, la mejor referencia que tenemos es la validación hacia adelante de 2009–2010, 0,664 y 0,711 (inferencia).

GRACIAS

¿Preguntas?

Grupo 7 — Andrés Cortese (64612) · Sebastián Caules (64331)
Instituto Tecnológico de Buenos Aires — 72.75 Aprendizaje Automático

Trabajo Práctico 2: clasificación supervisada — Defensa: 07/10/2026

PREGUNTAS

20/20

Gracias; quedamos a disposición para las preguntas.

A ACLARAR · PREGUNTAS PROBABLES

- **Esta slide queda puesta durante las preguntas.** No hay slides de respaldo: cada pregunta se contesta volviendo a la slide que corresponde (el mapa de páginas está al principio del banco) y sólo con lo que ella muestra (N0-15).

Los 10 minutos de preguntas

Respuestas cortas, con el dato al frente y su conjunto declarado, y sólo con lo que muestra la slide a la que se vuelve (N0-15). Entre corchetes, a qué slide volver y quién responde primero: el que presentó ese bloque. Las citas de clase son sólo las de «Convenciones». Si repreguntan por algo que la charla dice y la pantalla no muestra, se dice que no está en pantalla y se contesta con lo que sí se ve, sin ninguna cifra que no esté en la slide.

Para volver a una slide. El pie dice «n/20» y la página del PDF no coincide, por los overlays. Página de la última variante de cada slide: 1 → 1 · 2 → 4 · 3 → 8 · 4 → 10 · 5 → 12 · 6 → 14 · 7 → 19 · 8 → 22 · 9 → 23 · 10 → 26 · 11 → 27 · 12 → 29 · 13 → 30 · 14 → 31 · 15 → 34 · 16 → 38 · 17 → 40 · 18 → 42 · 19 → 44 · 20 → 45.

EL TEST Y LOS DATOS

1. ¿Por qué no evaluaron el test todavía?

[slide 14 · Sebastián]

Porque se evalúa una sola vez (slides 3 y 14), y una vez abierto ya no se puede cambiar nada sin que deje de ser independiente: se abre con todo lo demás cerrado, después del 30/09 (N0-1). *Si en la defensa siguiera cerrado:* la única estimación disponible es la de validación, 0,795 (slide 13), y sale algo optimista (slide 17); cuánto, no lo medimos (pregunta 10).

2. ¿Cómo garantizan que ninguna decisión miró el test?

[slide 3 · Andrés]

Por diseño, y la tabla lo muestra: el análisis exploratorio, las ablaciones y la validación cruzada leen sólo train; el test se usa una vez, al final, y no decide nada (D-04). Además, lo que se aprende de los datos —escalas, cortes— se ajusta dentro de cada fold, sólo con el de entrenamiento (slide 7). *Mientras siga cerrado,* la slide 14 lo muestra pendiente: se evalúa una vez, después del 30/09.

3. ¿Por qué partición aleatoria, si el archivo está ordenado por fecha?

[slides 5 y 19 · Sebastián]

El enunciado plantea k-fold y no menciona el tiempo, y con el último 20 % del archivo como test (la proporción de la slide 3) se entrenaría en una época y se evaluaría en otra: la tasa de «yes» va de 1,9 % a 50,9 % a lo largo del archivo (slide 5; D-03). Lo que cuesta no está escondido: está medido en las slides 18 y 19, y por eso la slide 14 dice «de la misma época».

4. ¿Por qué estratificaron, si no se vio en clase?

[slide 3 · Andrés]

Porque con 11,3 % de «yes» (slide 2), una partición al azar sin estratificar puede dejar al test con otra proporción de «yes» sólo por la semilla. Estratificar por y mantiene la misma en train y en test, y no cuesta nada (D-02).

5. ¿Por qué duration fuera, si es la mejor variable?

[slide 4 · Sebastián]

Porque se conoce al colgar, cuando y ya se sabe, y el modelo decide antes de llamar (slide 2; D-05). Con ella Random Forest llega a 0,939 de AUC de validación, pero ese número no existe antes de llamar, que es cuando opera el modelo (TP2, p. 1): la figura lo llama techo.

6. ¿Hay otras variables con fuga?

[slide 2 · Andrés]

Las demás son lo que el banco sabe antes de marcar: las cuatro cajas de la slide. La que tiene reserva es campaign, el «n.º de llamada»: cuenta la llamada que se va a hacer, pero si cada fila guarda el total de la campaña y, tras un «yes», no se vuelve a llamar, su valor final depende en parte del resultado (inferencia); el efecto no se midió (D-07). El mes, el día y el canal son de la llamada que se va a hacer, y se eligen antes de marcar (inferencia). Y el contexto económico delata la época (slide 5), pero eso es un problema de robustez temporal, no de fuga: es el hallazgo (slides 18 y 19; D-25).

7. ¿El mismo cliente puede estar en train y en test?

[slide 3 · Andrés]

No se puede descartar: la partición es de filas, 80/20 estratificado, y sólo se quitaron los 12 duplicados exactos (D-01). Si un cliente cae en train y en test, el test sale algo optimista; no lo podemos medir, y es una limitación más. Filas con los mismos datos y distinta respuesta explicarían también que KNN con un vecino no llegue a 1,0 en train (slide 11; inferencia).

DECISIONES DISCUTIBLES

8. ¿De dónde sale el 20 %?

[slides 8 y 17 · Andrés]

Es un supuesto de negocio, declarado como limitación (slide 17; D-20): el banco llama a una parte fija de la lista, y con el 20 % todos los modelos hacen las mismas llamadas, así que los recalls se comparan. La mejora que proponemos es un costo por tipo de error en lugar del 20 % fijo. No usamos el umbral de la Clase 4, el punto de la ROC más cercano a la esquina superior izquierda (slide 52), porque es simétrico entre los dos errores y aquí no cuestan lo mismo (slides 41–44); y con un umbral por modelo los recalls no se comparan.

9. ¿Por qué no trataron el desbalance, por ejemplo remuestreando?

[slide 8 · Andrés]

No remuestreamos: el pipeline de la slide 7 no tiene ese paso, porque las dos métricas ya no premian decir siempre «no» (D-19, D-21): un puntaje igual para todos da 0,500 de AUC y 0,200 de recall, aunque acierte el 88,7 %. Con ellas, el desbalance no engaña a la comparación. Y una corrección que sólo moviera el umbral no cambiaría el AUC, que no depende del umbral (Clase 4, slides 45–51).

10. ¿No sobreajustaron la validación con tantas decisiones?

[slide 17 · Sebastián]

Algo, y está declarado como limitación: «hiperparámetros elegidos con la misma validación». Es el sobreajuste a la validación de la Clase 3, slides 98–100: elegir el mejor entre muchas estimaciones con ruido también elige ruido favorable, así que el 0,795 de validación (slide 13) sale optimista, y no medimos cuánto. De las cuatro defensas del slide 100 usamos tres: validación cruzada (slide 3); búsquedas acotadas, una grilla corta por modelo, con la regla de un error estándar, que no elige el máximo (slides 10–12; D-22); y un test intacto que se abre una vez (slide 3; D-04). La cuarta, la validación cruzada anidada, no la corrimos: el test intacto ya cumple el papel de la evaluación externa. Lo que se promete es el número de test.

11. ¿Por qué no validaron hacia adelante como esquema principal?

[slide 19 · Andrés]

Porque el enunciado plantea k-fold, y un esquema temporal habría entrenado con la época de tasa baja para predecir la de tasa alta: los bloques de 2008 tienen de 4,7 % a 6,5 % de «yes», y el último, 35,2 % (D-25). Lo medimos dentro de train como limitación, y es la primera mejora: es como se usaría el modelo (slide 17).

LA TEORÍA DE LOS CUATRO MODELOS

12. ¿Qué supone Naive Bayes y cómo lo afectan estos datos?

[slides 9 y 16 · Sebastián]

Independencia de las variables dada la clase. El bloque macro la viola: tres de sus variables tienen, en train, correlaciones de 0,91 a 0,97 (slide 16), casi la misma información tres veces. Eso lleva las probabilidades a los extremos, pero el AUC mide el orden (inferencia). El gaussiano supone además una normal por clase, y pdays es casi binaria, con casi todas las filas en 999 (slide 6). Por eso el del TP es el categórico, que discretiza las numéricas y le gana al gaussiano: 0,782 contra 0,769 de AUC de validación (slide 9; D-18). Si repreguntan dónde se nota la violación: aclaraciones de la slide 16.

13. ¿Para qué la corrección de Laplace?

[slides 7 y 9 · Sebastián]

En el Naive Bayes categórico, un valor que en el fold de entrenamiento nunca aparece con «yes» tendría probabilidad 0 y anularía el producto, sin importar el resto de las variables. Laplace suma α a cada conteo: $(\text{conteo} + \alpha) / (N + k\alpha)$, con k los valores posibles del atributo (Clase 6, slide 46). Así ningún valor queda con probabilidad cero, y la corrección pesa más cuantas menos filas tiene un valor.

14. ¿Qué hace C en la SVM, y por qué quedó en 0,001?

[slide 12 · Andrés]

C es el costo de las violaciones del margen: un C grande castiga más y regulariza menos, como dice el eje (Clase 8, slide 49). Con kernel lineal la curva es plana en validación: 0,001 y 0,01 quedan a la misma altura, y la regla toma el más regularizado, 0,001, con 0,774 y brecha 0,002 (anotados). Con RBF, un C grande lleva train casi a uno y la validación cae: sobreajuste.

15. ¿Por qué lineal y no RBF? ¿Y y?

[slides 12 y 16 · Andrés]

Porque el RBF no lo mejora: en su mejor C da 0,772 de AUC de validación, contra 0,774 del lineal elegido (slide 16), y el lineal es más simple. y quedó fijo: la curva del RBF varía sólo C. Ajustarlo es la grilla conjunta de C y γ de la Clase 8, slides 48–49; con γ fijo, el RBF no superó al lineal.

16. ¿Por qué hay que escalar para KNN y la SVM, y no para Random Forest?

[slides 7 y 16 · Sebastián]

KNN y la SVM miden distancias, y sin escalar las decide la variable de mayor varianza (Clase 8, slide 54; Alpaydin §8.3, p. 192): sin escalar, en train, pdays sola es el 86,6 % de la varianza (slide 16), así que el vecino más cercano sería el de historial de contacto parecido, no el cliente parecido. Un árbol corta cada variable por separado, así que la escala no le cambia nada (D-12). Por eso la caja dice «codificar y escalar», «según el modelo» (slide 7).

17. ¿No es enorme k = 801? ¿Y la ponderación por distancia?

[slide 11 · Andrés]

En KNN sobreajusta el k pequeño: con un vecino, train queda cerca de 1,0 y validación apenas por encima de 0,6 (la figura). Al sumar vecinos la brecha se cierra, la validación forma una meseta en los k grandes, y se toma el más suave: 801, con 0,784 de validación y brecha 0,006 (anotados). Con 11,3 % de «yes» en train (slide 2), estimar bien una proporción baja pide muchos vecinos (inferencia). Por distancia (Mitchell §8.2.1), la línea punteada: en train queda en 1,0, porque cada punto de train se encuentra a sí mismo, y en validación, con más de un vecino, queda por debajo de la uniforme en todo el rango.

18. ¿k = 801 y C = 0,001 no quedaron en el borde de sus grillas?

[slides 11 y 12 · Andrés]

Sí, los dos, y no por la misma razón. En KNN, la validación es una meseta en los k grandes, y la regla elige el más suave de los que empatan: la meseta llega hasta el final de la grilla, 801, así que un k mayor probablemente también empataría, sin cambiar el AUC (inferencia). En la SVM, 0,001 es el menor C del eje: con kernel lineal la curva es plana, y la regla toma el más regularizado. Un C menor sería una SVM lineal aún más regularizada, y no la probamos: no sabemos si seguiría empatando o empezaría a subajustar.

19. ¿Por qué Random Forest no sobreajusta con más árboles, pero sí con más profundidad?

[slide 10 · Andrés]

La profundidad es la complejidad de cada árbol: sin límite, train llega al tope del eje y la validación baja («sobreajuste →»). Los árboles, en cambio, se promedian: bajan la varianza sin cambiar el sesgo (Clase 7, slide 61). El protocolo de las curvas —train y validación con los mismos folds, la brecha como lectura del sobreajuste— es el de la Clase 7, slide 50.

20. ¿Qué significa un AUC de 0,795?

[slides 8 y 13 · Andrés]

La probabilidad de que, tomando al azar un «yes» y un «no» de validación, el modelo le dé más puntaje al «yes». Sin modelo es 0,500. No depende del umbral y no premia decir siempre «no» (Clase 4, slides 45–51). Llamando al 20 % de la lista, eso se traduce en 0,629 de recall de validación. Esa lista mezcla las épocas, y ordenar dentro de un mismo año es más difícil: 0,658 en los pares del mismo año (slide 18; pregunta 24).

21. ¿Los modelos son realmente distinguibles?

[slide 13 · Sebastián]

Random Forest es el primero en las dos métricas: 0,795 de AUC y 0,629 de recall de validación, contra 0,784 y 0,617 de KNN, el segundo (D-23). Pero conviene decir la escala: los cuatro van de 0,774 a 0,795, y sin modelo es 0,5 (la línea punteada). Y el error estándar con el que la charla descarta un empate supone folds independientes, cuando sus train se superponen en tres cuartos: el real es algo mayor (inferencia).

22. ¿Por qué 5 folds?

[slide 3 · Andrés]

Cada vuelta valida con uno de los 5 folds de train y ajusta con los otros cuatro (la tabla: «train, en 5 folds»; D-06). Las barras de ± 1 desvío entre folds de la slide 9 son cortas frente a la distancia a sin modelo, así que la estimación ya es estable (inferencia). No comparamos otros k. Lo que sí importa es que los folds estén barajados: sin barajar, cada uno quedaría en una época (slides 5 y 7).

EL HALLAZGO

23. ¿El hallazgo no invalida el modelo?

[slides 18–19 · Andrés]

No invalida el número de test: dice qué mide. El test es de las mismas campañas (slide 17), así que vale para clientes nuevos de esas campañas, ordenados en una lista que las mezcla (pregunta 24). Hacia adelante, en los dos bloques de 2009–2010, Random Forest conserva 0,664 y 0,711: pierde, pero no cae al azar. En 2008 no servía ni barajado: de 0,519 a 0,584 en esos bloques.

24. Si el banco elige a quién llamar dentro de una campaña, ¿cuánto valen el AUC y el recall?

[slide 18 · Andrés]

Menos. El 0,795 y el 0,629 de validación (slide 13) ordenan una lista que mezcla las épocas, y parte de su valor es reconocer la época: en los pares «yes»–«no» del mismo año el AUC baja a 0,658, contra 0,864 en los de años distintos (D-25, lectura (a)). El recall dentro de una campaña no está en las slides; también baja (inferencia), y su vara sigue siendo el 0,200 de sin modelo (slide 8). El test es la misma mezcla (slide 17): tendrá el mismo sesgo.

25. ¿No es sólo que las variables económicas delatan la fecha?

[slides 19 y 16 · Andrés]

En parte, sí. Barajado, sacar el bloque macro y month le cuesta a Random Forest 0,059 (slide 16): reconocer la época ayuda cuando las épocas se mezclan. Hacia adelante, si el modelo sólo reconociera la época, frente a una nueva ordenaría como el azar, cerca de 0,5, y eso dan los dos primeros bloques de 2008, 0,489 y 0,500 (slide 19). En el tercero da 0,426, por debajo de sin modelo: el orden se invierte, y eso sugiere que además la relación entre las variables y el «yes» cambia con el tiempo (inferencia). Pero es un solo bloque y sin intervalo: un indicio, no una prueba.

26. ¿Qué harían distinto con más tiempo?

[slide 17 · Sebastián]

Por impacto, lo de la slide: validar hacia adelante como esquema principal, que mide una campaña futura; más historial del cliente, porque el 86,3 % de train no tiene campaña previa; y un costo por tipo de error en lugar del 20 % fijo (Clase 4, slides 41–44). Para usar ese costo harían falta probabilidades calibradas: hoy las dos métricas sólo miden el orden (slide 8; inferencia).

27. ¿Y si el test da bastante distinto que validación?

[slide 14 · Sebastián]

Depende de cuánto. Se nombran los dos valores, el AUC de test de la slide y el 0,795 de validación (slide 13), y la distancia se lee contra la variación entre folds de validación (la barra de la slide 18) y contra el intervalo de test. Dentro de esa variación es ruido, en cualquier sentido. Si da algo más bajo, puede sumarse el optimismo que declaramos en la slide 17, que no medimos (pregunta 10), y por eso no sirve para descartar nada: una diferencia mayor que esa variación obliga a revisar la partición o el pipeline, buscando qué separa al test de train, y se dice tal cual. En ningún caso se cambia el modelo después de abrirlo: lo que se promete es el número de test. Y en ningún caso se lo compara con «sin modelo» (slide 3: el test no decide nada).