

TP2: predecir quién contrata un plazo fijo

Qué pide el enunciado, qué trae el dataset Bank Marketing y qué hay que decidir antes del envío

Documento de lectura para el grupo, 25/09/2026. Fuentes en gris: TP2 = enunciado; CSV = bank-additional-full.csv, cálculo propio; names = bank-additional-names.txt.



Fechas: TP2, p. 1 · cronograma de la Clase 1. KNN el 30/09 es **INFERENCIA**; el envío es el 06/10 si el grupo defiende el 07/10.

LLAMADAS 41.188 20 predictoras + y CSV	CONTRATAN 11,27 % 4.640; decir siempre «no» acierta 88,73 % CSV	CLASIFICADORES 4 Naive Bayes, SVM, KNN, RF TP2, p. 2	DEFENSA 10 + 10 minutos; envío 24 h antes TP2, p. 1
--	--	---	--

En una página

Qué pide. Predecir si un cliente contrata un depósito a plazo fijo (y = yes/no) con Naive Bayes, SVM, KNN y Random Forest en scikit-learn TP2, pp. 1–2. Se evalúa con *k-fold* sólo sobre entrenamiento, dos métricas justificadas y curvas de validación para al menos un hiperparámetro de SVM, KNN y RF; el modelo final estima su desempeño en datos nuevos. El EDA puede ser básico, pero sus observaciones tienen que tener consecuencias en el pipeline.

Qué trae el dato. Una llamada de cada nueve termina en «sí», así que la exactitud sola no sirve. Hay tres trampas: *duration* mira el futuro, hay faltantes disfrazados (*unknown*, *pdays* = 999) y el archivo está ordenado por fecha: la tasa de «sí» pasa de 4,84 % (2008) a 52,14 % (2010, año inferido) *names* §4 · CSV.

Qué sigue. Seis decisiones antes del envío (→ Próximos pasos: seis decisiones antes del envío). Tres conviene consultarlas con la cátedra: *duration*, partir al azar o por fecha, y si F_1 está entre las métricas vistas.

Antes de entrenar. *duration* no existe antes de llamar. Los autores piden descartarla para un modelo realista *names* §7, y sola separa las clases con AUC 0,818 *csv*. Un modelo que la usa parece excelente y no sirve.

EN ESTE DOCUMENTO


01 El enunciado evalúa cómo se valida, más que qué modelo gana | **02** El dataset: 20 predictoras en cuatro grupos y una clase de cada nueve | **03** Dos trampas que cambian lo que mide la evaluación | **04** Qué le hace este dataset a cada uno de los cuatro modelos | **05** Próximos pasos: seis decisiones antes del envío | Glosario



La consigna, en el orden del enunciado. Azul oscuro: hecho; celeste: en curso TP2, pp. 1–2.

01 El enunciado evalúa cómo se valida, más que qué modelo gana

El objetivo declarado es «aprender a entrenar y evaluar modelos utilizando validación cruzada» TP2, p. 1: el test se separa primero y toda transformación aprendida se ajusta sólo con entrenamiento.



Nada pasa del carril del test al de entrenamiento. Separar antes de transformar lo pide el enunciado TP2, p. 1; usar el test una vez y reentrenar con todo el train es **INFERENCIA**.

MODELO	QUÉ PIDE EVALUAR	QUÉ MIRAR EN ESTE DATASET
Naive Bayes	ningún hiperparámetro TP2, p. 2	el enunciado no dice qué variante; hay 10 numéricas y 10 categóricas csv
SVM	C o kernel TP2, p. 2	escalar es obligatorio; con 41.188 filas es el más caro de entrenar INFERENCIA
KNN	número de vecinos, ponderación TP2, p. 2	escalar; con 11,27 % de «sí», un k grande vota «no» casi siempre INFERENCIA
Random Forest	número de árboles, profundidad máxima TP2, p. 2	no necesita escalar; con duration adentro, los cortes la eligen a ella INFERENCIA


Lo que el enunciado no dice, y queda a criterio del grupo:

- **Qué Naive Bayes** para datos mixtos.
- **Cuántos pliegues y si se estratifica.**
- **Si se trata el desbalance.** Pide mirar «el balance de clases» TP2, p. 1, no corregirlo.
- **Qué variable filtra.** Advierte sobre la fuga sin nombrar ninguna TP2, p. 1.
- **El tamaño del test y el umbral de decisión.**

Del TP1 arrastra tres consejos TP2, pp. 2–3: decir qué datos se usan en cada etapa, preferir gráficos a tablas y no pasar de 10 minutos, con los números en las slides. El objetivo dice «regresión»: copia del TP1 TP1, p. 1.


02 El dataset: 20 predictoras en cuatro grupos y una clase de cada nueve

Cada fila es un contacto telefónico de un banco portugués entre mayo de 2008 y noviembre de 2010 ^{names §4}. Sólo uno de los cuatro grupos describe la llamada misma.




Los grupos de ^{names §7}. duration es del último contacto, pero se conoce recién al colgar: va tras la línea.

¿Contrató el depósito? (y)




Decir siempre «no» acierta el 88,73 %: es la línea de base de cualquier exactitud csv.

Filas con «unknown», por columna



Ningún NaN: los faltantes vienen como la categoría unknown ^{names §8} · CSV.

- **10 numéricas y 10 categóricas.** Las categóricas suman 53 niveles: *one-hot* sin descartar da 53 columnas csv.
- **Un cuarto de las filas tiene algún unknown** (25,98 %); en default, 8.597 contra sólo 3 «yes» csv.
- **Categorías raras.** default = yes (3 filas, ninguna con «sí») e illiterate (18): sin Laplace, Naive Bayes puede darles probabilidad cero csv.
- **12 filas duplicadas exactas:** al partir, una copia puede quedar en cada lado csv.



Porcentaje de «sí» por nivel; la línea punteada es el 11,27 % global y el gris marca categorías con menos del 1 % de las filas. month lleva la época adentro: marzo, abril y septiembre no tienen filas de 2008, y octubre y diciembre casi ninguna csv.

pdays = 999 no siempre significa «nunca contactado»




El 96,32 % de las filas tiene 999; 4.110 de ellas sí tuvieron contacto previo csv.

El diccionario define el 999 como «no contactado antes» ^{names §7}, pero 4.110 filas con 999 tienen previous ≥ 1 csv. El indicador fiable es previous = 0. Como número, el 999 aplasta las distancias de KNN y SVM **INFERENCIA**: mejor una indicadora más los días reales **PROPUESTA**.

03 Dos trampas que cambian lo que mide la evaluación

duration predice porque mira el futuro

% de «yes» según cuánto duró la llamada




Ninguna llamada de menos de 30 segundos terminó en «sí»; las 4 de 0 segundos, en «no» csv.

La duración se conoce cuando la llamada termina, que es cuando ya se sabe la respuesta. Encaja con la advertencia del enunciado sobre información que no está «antes de realizar la llamada» TP2, p. 1 **INFERENCIA**. Entre las decisiones del EDA, el enunciado nombra «la exclusión de alguna variable» y comparar el modelo «con y sin ciertas variables problemáticas» TP2, p. 1.


El archivo está ordenado por fecha, y la tasa de «sí» cambia con ella

El archivo va de 2008 a 2010, y la tasa sube con el tiempo



Sin barajar, cada pliegue es otra época: de 3,1 % a 30,8 % de «sí» csv.

% de «yes» por año






El año no está en el archivo: se infiere del ciclo de meses names \$4 · CSV.

`train_test_split` baraja por defecto (documentación de scikit-learn) y los pliegues dejan de ser épocas. Pero la estimación mide el desempeño dentro de las mismas épocas; partir por fecha se parece más a usar el modelo en campañas futuras **INFERENCIA**. La cátedra no dijo cuál espera.

04 Qué le hace este dataset a cada uno de los cuatro modelos

El punto 5 pide mencionar si los datos se ajustan a los supuestos de los modelos, con cuatro ejemplos: variables correlacionadas, distribuciones no gaussianas, diferencias de escala y relaciones no lineales TP2, p. 2. Los cuatro están en el dataset.



Recuadro: tres indicadores macro con r entre 0,91 y 0,97. Para Naive Bayes, la misma evidencia contada tres veces csv.

El «sí» sube en los dos extremos de edad: una relación no lineal csv.

MODELO	QUÉ LE PASA CON ESTOS DATOS
Naive Bayes	el bloque macro rompe la independencia condicional; las numéricas son asimétricas y pdays es bimodal, mala forma para una normal por clase INFERENCIA
SVM	sin escalar, la frontera la deciden duration y pdays INFERENCIA ; los desvíos van de 0,5 a 259 csv
KNN	la misma escala, más 53 columnas <i>one-hot</i> csv mezcladas con numéricas en una sola distancia
Random Forest	inmune a la escala; reparte los cortes entre tres variables macro casi iguales y diluye su importancia INFERENCIA

05

Próximos pasos: seis decisiones antes del envío

Las fechas intermedias son propuesta. La fija es el envío, 24 h antes de la clase en que se presenta TP2, p. 1: 06/10 si el grupo defiende el 07/10, 13/10 si defiende el 14/10.

QUÉ	QUIÉN	PARA
duration: excluirla o comparar el modelo con y sin ella	grupo; consultar a la cátedra	30/09 PROPUESTA
Partición: barajar y estratificar, o partir por fecha	grupo; consultar a la cátedra	30/09 PROPUESTA
Faltantes: unknown como categoría; indicadora previous > 0 en lugar del 999	grupo	30/09 PROPUESTA
Métricas: dos que no premien decir siempre «no»; ¿ F_1 está entre «las vistas en clase»?	grupo; consultar a la cátedra	02/10 PROPUESTA
Naive Bayes: qué variante para 10 numéricas y 10 categóricas	grupo	02/10 PROPUESTA
Escala y colinealidad: escalar dentro del pipeline para SVM y KNN; decidir si queda una sola variable macro	grupo	02/10 PROPUESTA
Enviar presentación y código	grupo	06/10 o 13/10 TP2, p. 1

Cifras para tener a mano

QUÉ	VALOR	FUENTE
Filas × columnas	41.188 × 21	CSV
«yes» / «no»	4.640 (11,27 %) / 36.548	CSV
Exactitud de decir siempre «no»	88,73 %	CSV
AUC de duration sola	0,818	CSV
Filas con algún unknown	10.700 (25,98 %)	CSV
pdays = 999 / con contacto previo	39.673 (96,32 %) / 4.110	CSV
«yes» por año inferido	4,84 % · 19,48 % · 52,14 %	names §4 · CSV
Correlación del bloque macro	0,91 a 0,97	CSV
Varianza de duration + pdays	95,0 % del total	CSV
Duplicados exactos	12	CSV

Glosario

Depósito a plazo fijo. *Term deposit:* el producto que se ofrece en la llamada; *y* dice si el cliente lo contrató.

Fuga de datos. *Data leakage:* información que debería estar sólo del lado de la evaluación entra al entrenamiento, y las métricas mienten hacia arriba. En el TP2, también una variable que no existe antes de llamar.

Centinela. Un valor que no es un número sino una marca, como el 999 de pdays.

Curva de validación. *Validation curve:* cómo varía el rendimiento al cambiar un hiperparámetro Clase 7, slide 50; el TP2 pide usarlas «para elegir el mejor valor» TP2, p. 2.